

Statystyka – wstęp Junior Data Scientist

infoShare Academy



HELLO

Wojciech Artichowicz



Nasze cele

- Praktyczne umiejętności (how-to in python)
- Wprowadzenie i szczegółowe objaśnienie formalizmu matematycznego
- Teoria podstawowych metod statystycznych używanych w data science
- Głębokie zrozumienie podstawowych metod statystycznych
- Uzyskanie solidnych podstaw do samodzielnego studiowania bardziej skomplikowanych zagadnień

Zakres zagadnień

1. Podstawy prawdopodobieństwa i statystyki (formalizm)
2. Statystyka opisowa
3. Wnioskowanie statystyczne (przedziały ufności i testy statystyczne)



01. Terminy podstawowe




Statystyka

Statystyka – nauka zajmująca się analizowaniem i liczbowym opisem zjawisk masowych.


Statystyka matematyczna – dział matematyki zajmujący się metodami wnioskowania o populacji na podstawie losowych prób z tej populacji.

Słownik języka polskiego PWN

Statystyka



Statystyka i Data Science



Podstawowa klasyfikacja

Statystyka

Opisowa

Matematyczna

Wizualizacja
danych

Generalizacja
danych

Estymacja

Wnioskowanie

Predykcja

Eksperyment

Uzyskanie wyniku lub wyników doświadczenia losowego. Np.:

- wynik rzutu kostką do gry
- odpowiedź respondenta na pytanie
- wynik badania medycznego (np. pomiar stężenia glukozy we krwi)
- wyniki sprzedaży produktu
- ...

Skończona lub nieskończona kolekcja obiektów, w której kolejność nie ma znaczenia, oraz ignorowany jest fakt, że element występuje więcej niż raz w zbiorze.

Fakt przynależności danego elementu do zbioru zapisuje się jako $a \in A$.

Zbiór (przykład)

Te zbiory są identyczne

$$A=\{a,1,2,3\}$$

$$B=\{2,a,1,3\}$$


$$C=\{3,2,1,a\}$$

Zbiór (przykład)

Przykłady zbiorów:

- $A = \{ \begin{array}{|c|} \hline \cdot \\ \hline \end{array}, \begin{array}{|c|} \hline \cdot \cdot \\ \hline \end{array}, \begin{array}{|c|} \hline \cdot \cdot \cdot \\ \hline \end{array}, \begin{array}{|c|} \hline \cdot \cdot \cdot \cdot \\ \hline \end{array}, \begin{array}{|c|} \hline \cdot \cdot \cdot \cdot \cdot \\ \hline \end{array}, \begin{array}{|c|} \hline \cdot \cdot \cdot \cdot \cdot \cdot \\ \hline \end{array} \}$
- pracownicy przedsiębiorstwa
- stany kontrolki na stronie internetowej
- klienci firmy
- produkty w sklepie internetowym
- stan produktu w sklepie internetowym

Zbiory: podstawowe oznaczenia




$\emptyset$ – zbiór pusty

S – zbiór uniwersum

A' – dopełnienie zbioru A (wszystko poza zbiorem A)

Zbiory: podstawowe operacje




$\cup$ – suma zbiorów

$\cap$ – iloczyn zbiorów

$-$ – różnica zbiorów

Dopełnienie zbioru




A' jest zbiorem zawierającym wszystkie elementy S , poza tymi, które znajdują się w zbiorze A .

Zbiory A i A' są parami rozłączne: $A \cap A' = \emptyset$

Sumą zbiorów A oraz A' jest S : $A \cup A' = S$

Inne oznaczenia spotykane w literaturze: A^C and $\bar{A}$.


Zbiory parami rozłączne



Zbiory A i B są parami rozłączne jeśli ich iloczynem jest zbiór pusty.

$$A \cap B = \emptyset$$


Suma (alternatywa) zbiorów



Alternatywą zbiorów A i B jest zbiór zawierający elementy ze zbioru A **lub** B .

$$A \cup B$$


Iloczyn (przecięcie) zbiorów



Iloczynem zbiorów A i B jest zbiór zawierający elementy ze zbioru A i B .

$$A \cap B$$


Różnica zbiorów



Różnicą zbiorów A i B jest zbiór zawierający elementy ze zbioru A , które **nie znajdują się** w zbiorze B .

$$A - B$$

Zawieranie zbiorów



Zbiór A jest podzbiorem B jeśli wszystkie jego elementy znajdują się w zbiorze B .

Iloczyn kartezjański zbiorów

Iloczynem kartezjańskim zbiorów nazywamy zbiór uporządkowany punktów (krotek) (a,b) , gdzie $a \in A$ i $b \in B$.

$$A \times B$$

Iloczyn kartezjański zbiorów (przykład)

$$A=\{1,2,3\}; B=\{a,b\}$$

$$A \times B = \{ (1,a), (1,b), \\ (2,a), (2,b), \\ (3,a), (3,b) \}$$

Zdarzenie

Zdarzenia są to zbiory i elementy zbiorów w rachunku prawdopodobieństwa.

Zdarzenie elementarne

Pojęcie pierwotne rachunku prawdopodobieństwa (tzn. nie posiada formalnej definicji).

Potocznie: najmniejszy niepodzielny wynik doświadczenia losowego.

Przestrzeń zdarzeń elementarnych Ω

Zbiór wszystkich możliwych wyników doświadczenia losowego.

Jest to odpowiednik zbioru uniwersum.

Przestrzeń zdarzeń elementarnych Ω (przykład)



Przestrzeń zdarzeń elementarnych pojedynczego rzutu kostką (czyli wszystkie możliwe wyniki takiego eksperymentu)

$$\Omega = \left\{ \begin{array}{|c|} \hline \cdot \\ \hline \end{array}, \begin{array}{|c|} \hline \cdot \cdot \\ \hline \end{array}, \begin{array}{|c|} \hline \cdot \cdot \cdot \\ \hline \end{array}, \begin{array}{|c|} \hline \cdot \cdot \cdot \cdot \\ \hline \end{array}, \begin{array}{|c|} \hline \cdot \cdot \cdot \cdot \cdot \\ \hline \end{array}, \begin{array}{|c|} \hline \cdot \cdot \cdot \cdot \cdot \cdot \\ \hline \end{array} \right\}$$

Przestrzeń zdarzeń elementarnych Ω (przykład)

Przestrzeń zdarzeń elementarnych dwukrotnego rzutu monetą (czyli wszystkie możliwe wyniki takiego eksperymentu)



$$\Omega = \{(\text{crown}, \text{crown}), (\text{crown}, \text{B}), (\text{B}, \text{crown}), (\text{B}, \text{B})\}$$

Przestrzeń zdarzeń elementarnych Ω (przykład)



$$\Omega = \{(a, a, a, \dots, a), \\ (b, a, a, \dots, a), \\ (c, a, a, \dots, a), \\ (d, a, a, \dots, a), \\ (a, b, a, \dots, a), \\ \dots, \\ (d, d, d, \dots, c), \\ (d, d, d, \dots, d)\}$$

Przestrzeń zdarzeń elementarnych eksperymentu polegającego na wypełnieniu ankiety:
układ wszystkich możliwych odpowiedzi na każde pytanie.

Zdarzenie losowe

Eksperyment nazywa się losowym jeśli przy powtarzaniu go w tych samych warunkach jego wynik nie może być przewidziany, a wszystkie możliwe wyniki mogą zostać określone przed jego przeprowadzeniem.

Zdarzenie losowe (przykład)

- Rzut monetą
- Liczba wypadków samochodowych w danym dniu
- Partia, na którą zagłosuje pytana osoba
- Wystąpienie katastrof naturalnych
- Cena akcji na rynku
- Liczba klientów, która zakupi produkt
- ...

Zdarzenie losowe: typy

Wyróżnia się dwa typy zdarzeń losowych:

- proste
- złożone

Np. w eksperymencie polegającym na rzucie kostką:

- zdarzenie proste: otrzymano 
- zdarzenie złożone: otrzymano parzystą liczbę oczek, czyli: ,  lub .

Zdarzenie pewne

Zdarzenie, w którego skład wchodzi wszystkie elementy przestrzeni zdarzeń elementarnych (czyli zdarzy się na pewno).

Zdarzenie pewne oznacza się symbolem Ω .

Zdarzenie niemożliwe

Zdarzenie, które nie zawiera żadnych elementów.

Zdarzenie niemożliwe oznacza się symbolem zbioru pustego, czyli $\emptyset$.

Ćwiczenie 1 (praca ze zbiorami)

Pewna firma rozważa dołączanie do zakupu pakietu próbek kosmetyków. Do wyboru jest 10 różnych produktów, przy czym pakiet testowy ma się składać z próbek 3 różnych produktów. Ile jest możliwych pakietów próbek? Wypisz wszystkie rodzaje pakietów gratisowych.

Ćwiczenie 1

Jest to zadanie wymagające zastosowania zależności kombinatorycznych.

- kolejność wybieranych elementów jest bez znaczenia (liczy się czy produkt jest w zestawie czy nie, a nie na którym miejscu);
- produkty nie mogą się powtarzać w zestawie promocyjnym.

Powyższe wymagania sugerują konieczność zastosowania kombinacji:

$$C_{k,N} = \binom{N}{k} = \frac{N!}{k! (N - k)!}$$

Ćwiczenie 1 (rozwiązanie)

$$C_{k,N} = \binom{10}{3} = \frac{10!}{3!(10-3)!} = 120$$

$\Omega = \{$
(1, 2, 3), (1, 2, 4), (1, 2, 5), (1, 2, 6), (1, 2, 7), (1, 2, 8), (1, 2, 9), (1, 2, 10), (1, 3, 4), (1, 3, 5), (1, 3, 6), (1, 3, 7),
(1, 3, 8), (1, 3, 9), (1, 3, 10), (1, 4, 5), (1, 4, 6), (1, 4, 7), (1, 4, 8), (1, 4, 9), (1, 4, 10), (1, 5, 6), (1, 5, 7), (1, 5, 8),
(1, 5, 9), (1, 5, 10), (1, 6, 7), (1, 6, 8), (1, 6, 9), (1, 6, 10), (1, 7, 8), (1, 7, 9), (1, 7, 10), (1, 8, 9), (1, 8, 10), (1, 9, 10),
(2, 3, 4), (2, 3, 5), (2, 3, 6), (2, 3, 7), (2, 3, 8), (2, 3, 9), (2, 3, 10), (2, 4, 5), (2, 4, 6), (2, 4, 7), (2, 4, 8), (2, 4, 9),
(2, 4, 10), (2, 5, 6), (2, 5, 7), (2, 5, 8), (2, 5, 9), (2, 5, 10), (2, 6, 7), (2, 6, 8), (2, 6, 9), (2, 6, 10), (2, 7, 8), (2, 7, 9),
(2, 7, 10), (2, 8, 9), (2, 8, 10), (2, 9, 10), (3, 4, 5), (3, 4, 6), (3, 4, 7), (3, 4, 8), (3, 4, 9), (3, 4, 10), (3, 5, 6), (3, 5, 7),
(3, 5, 8), (3, 5, 9), (3, 5, 10), (3, 6, 7), (3, 6, 8), (3, 6, 9), (3, 6, 10), (3, 7, 8), (3, 7, 9), (3, 7, 10), (3, 8, 9), (3, 8, 10),
(3, 9, 10), (4, 5, 6), (4, 5, 7), (4, 5, 8), (4, 5, 9), (4, 5, 10), (4, 6, 7), (4, 6, 8), (4, 6, 9), (4, 6, 10), (4, 7, 8), (4, 7, 9),
(4, 7, 10), (4, 8, 9), (4, 8, 10), (4, 9, 10), (5, 6, 7), (5, 6, 8), (5, 6, 9), (5, 6, 10), (5, 7, 8), (5, 7, 9), (5, 7, 10), (5, 8, 9),
(5, 8, 10), (5, 9, 10), (6, 7, 8), (6, 7, 9), (6, 7, 10), (6, 8, 9), (6, 8, 10), (6, 9, 10), (7, 8, 9), (7, 8, 10), (7, 9, 10), (8, 9, 10)
 $\}$

Ćwiczenie 1 (rozwiązanie)

W języku python do obliczenia wartości dwumianu Newtona (kombinacja) można wykorzystać funkcję `binom` z modułu `scipy.special`.

Natomiast do generowania różnych schematów kombinatorycznych można wykorzystać bibliotekę `itertools`.



Prawdopodobieństwo

Definicja, własności, interpretacje

Aksjomatyczna definicja prawdopodobieństwa

Aksjomat I. Dla każdego $A \in \Omega$

$$P(A) \geq 0$$

Aksjomat II. Prawdopodobieństwo zdarzenia pewnego

$$P(\Omega) = 1$$

Aksjomat III. Dla każdej pary $A_1, A_2, \dots$ of zdarzeń rozłącznych parami zachodzi

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$$

Niektóre własności prawdopodobieństwa

- Prawdopodobieństwo zdarzenia niemożliwego wynosi zero

$$P(\emptyset) = 0$$

- Prawdopodobieństwo zdarzenia przeciwnego równe jest

$$P(A') = 1 - P(A)$$

- Dla dowolnych dwóch zdarzeń zachodzi

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

- Jeśli $A \subset B$, to

$$P(A) \leq P(B)$$

- Dla każdego zdarzenia A

$$P(A) \leq 1$$

Klasyczna interpretacja prawdopodobieństwa (przypadek szczególny)

Niech wyniki doświadczenia losowego będą jednakowo prawdopodobne i niech możliwych wyników tego doświadczenia będzie N . Jeżeli zdarzenie A składa się z k elementów (czyli k zdarzeń elementarnych, tzw. zdarzeń sprzyjających), to

$$P(A) = \frac{k}{N}$$

Klasyczna interpretacja prawdopodobieństwa (przypadek szczególny) (przykład)



Prawdopodobieństwo otrzymania $\begin{bmatrix} \cdot & \cdot \\ \cdot & \cdot \end{bmatrix}$ wynosi:

$$P\left(\begin{bmatrix} \cdot & \cdot \\ \cdot & \cdot \end{bmatrix}\right) = \frac{1}{6}$$

Klasyczna interpretacja prawdopodobieństwa (przypadek szczególny) (przykład)



Prawdopodobieństwo otrzymania liczby oczek mniejszej niż 3 wynosi:

$$P(\boxed{\cdot} \cup \boxed{\cdot \cdot}) = P(\boxed{\cdot}) + P(\boxed{\cdot \cdot}) = \frac{1}{6} + \frac{1}{6} = \frac{1}{3}$$

Klasyczna interpretacja prawdopodobieństwa


Niech przestrzeń zdarzeń elementarnych składa się z N elementów

$$\Omega = \{\omega_1, \omega_2, \dots, \omega_N\}$$

i niech prawdopodobieństwo zajścia zdarzenia elementarnego ω_i wynosi $P(\omega_i)$. Wówczas, dla każdego zdarzenia $A \subset \Omega$

$$P(A) = \sum_{\omega_i \in A} P(\omega_i)$$

Klasyczna interpretacja prawdopodobieństwa (przykład)



Dana jest kostka sześcienna jak na rysunku (dwie ściany szare, cztery czerwone). Określ prawdopodobieństwa zdarzeń polegających na tym, że w wyniku pojedynczego rzutu otrzyma się ścianę:

- czerwoną
- szarą

$$\Omega = \{\bullet, \bullet\}$$

$$P(\bullet) = 4/6$$

$$P(\bullet) = 2/6$$

Geometryczna interpretacja prawdopodobieństwa




W n -wymiarowej przestrzeni, prawdopodobieństwo można interpretować jako stosunek objętości ($n=1$ – długości, $n=2$ - pola) brył

$$P(A) = \frac{v}{V}$$


v – objętość bryły reprezentującej zbiór zdarzeń
sprzyjających

V – objętość bryły będącej przestrzenią elementarną

Geometryczna interpretacja prawdopodobieństwa (przykład)




Geometryczna interpretacja prawdopodobieństwa (przykład)



Dany jest odcinek o długości $L=2\text{m}$. Jakie jest prawdopodobieństwo zdarzenia A , że losowo wybrany punkt znajdzie się w zbiorze $I=\{x: x>0 \text{ i } x<0,25 \text{ m}\}$?

$$P(A) = \frac{l}{L} = \frac{0,25}{2} = \frac{1}{8}$$

Geometryczna interpretacja prawdopodobieństwa (przykład)



Jakie jest prawdopodobieństwo, że łucznik trafi w „10” jeśli średnica tarczy wynosi D a średnica obszaru „10” d . Założyć, że łucznik zawsze trafia w tarczę, a szansa trafienia w którykolwiek jej punkt jest taka sama.

$$P(A) = \frac{A_{10}}{A_T} = \frac{\frac{\pi d^2}{4}}{\frac{\pi D^2}{4}} = \frac{d^2}{D^2}$$

Statystyczna interpretacja prawdopodobieństwa

Prawdopodobieństwo zdarzenia A równe jest

$$P(A) = \lim_{N \rightarrow \infty} \frac{k}{N}$$

k – liczba eksperymentów w których otrzymano
zdarzenie sprzyjające

N – liczba wszystkich eksperymentów


Prawdopodobieństwo warunkowe

Niech A i B będą dowolnymi zdarzeniami, $A \subset \Omega$ i $B \subset \Omega$, przy czym prawdopodobieństwo zdarzenia A jest dodatnie $P(A) > 0$.

Prawdopodobieństwo warunkowe zdarzenia B pod warunkiem zajścia zdarzenia A jest dane wzorem:

$$P(B|A) = \frac{P(A \cap B)}{P(A)}$$

Prawdopodobieństwo warunkowe




Prawdopodobieństwo wystąpienia zdarzenia B , pod warunkiem, że wystąpiło zdarzenie A jest równe prawdopodobieństwu wystąpienia zdarzenia $A \cap B$ pod warunkiem wystąpienia zdarzenia A .

$$P(B|A) = P(A \cap B|A)$$

Prawdopodobieństwo warunkowe (objaśnienia)


Jeśli wystąpiło jakieś zdarzenie A , a rozważane jest inne zdarzenie B , oznacza to, że przestrzeń zdarzeń elementarnych została zredukowana z Ω do A .



Prawdopodobieństwo warunkowe (objaśnienia)


- Prawdopodobieństwo (nie warunkowe) zdarzenia i prawdopodobieństwo warunkowe są jakościowo innymi pojęciami:
 - Prawdopodobieństwo znalezienia programisty, który zna język R
 - Prawdopodobieństwo znalezienia programisty, który zna język R jeśli pracuje jako data scientist

Prawdopodobieństwo warunkowe (objaśnienia)



$$P(R) = \frac{\bar{\bar{R}}}{\text{programiści}}$$

Prawdopodobieństwo warunkowe (objaśnienia)



$$P(R|DS) = \frac{P(DS \cap R)}{P(DS)}$$

Inna przestrzeń zdarzeń elementarnych!

Ćwiczenie 2

Na podstawie danych Github dotyczących użycia języków programowania oraz środowisk programistycznych obliczyć prawdopodobieństwo, że respondent

- używa języka Python
- używa środowiska Jupyter
- używa środowiska Jupyter oraz Pythona
- używa środowiska Jupyter jeśli wiadomo, że używa Pythona
- używa Pythona jeśli wiadomo, że używa środowiska Jupyter

Ćwiczenie 2

Przygotowanie (python) danych na temat częstości wystąpienia preferencji dotyczących języków programowania i środowisk:

		Język programowania	
		Python	Inne
Środowisko	Jupyter	<code>sum((df["jupyter"]==True) & (df["python"]==True))</code>	<code>sum((df["python"]==False) & (df["jupyter"]==True))</code>
	Nie Jupyter	<code>sum((df["python"]==True) & (df["jupyter"]==False))</code>	<code>sum((df["python"]==False) & (df["jupyter"]==False))</code>

Ćwiczenie 2

Rozmiar próby (liczba wszystkich odpowiedzi respondentów)

		Język programowania	
		Python	Inne
Środowisko	Jupyter	628	66
	Nie Jupyter	7395	9372

$$N = 628 + 66 + 7395 + 9372 = 17461$$

Ćwiczenie 2

Prawdopodobieństwo, że respondent
używa języka Python

		Język programowania	
		Python	Inne
Środowisko	Jupyter	628	66
	Nie Jupyter	7395	9372

Ćwiczenie 2

Prawdopodobieństwo, że respondent używa języka Python

		Język programowania	
		Python	Inne
Środowisko	Jupyter	628	66
	Nie Jupyter	7395	9372

$$P(\text{Python}) = \frac{628 + 7395}{17461} = 0,46$$

Ćwiczenie 2

Prawdopodobieństwo, że respondent
używa środowiska Jupyter

		Język programowania	
		Python	Inne
Środowisko	Jupyter	628	66
	Nie Jupyter	7395	9372

Ćwiczenie 2

Prawdopodobieństwo, że respondent
używa środowiska Jupyter

		Język programowania	
		Python	Inne
Środowisko	Jupyter	628	66
	Nie Jupyter	7395	9372

$$P(Jupyter) = \frac{628 + 66}{17461} = 0,0398$$

Ćwiczenie 2

Prawdopodobieństwo, że respondent
używa środowiska Jupyter oraz Pythona

		Język programowania	
		Python	Inne
Środowisko	Jupyter	628	66
	Nie Jupyter	7395	9372

Ćwiczenie 2

Prawdopodobieństwo, że respondent
używa środowiska Jupyter oraz Pythona

		Język programowania	
		Python	Inne
Środowisko	Jupyter	628	66
	Nie Jupyter	7395	9372

$$P(Jupyter \cap Python) = \frac{628}{17461} = 0,036$$

Ćwiczenie 2

Prawdopodobieństwo, że respondent używa środowiska Jupyter jeśli wiadomo, że używa Pythona

		Język programowania	
		Python	Inne
Środowisko	Jupyter	628	66
	Nie Jupyter	7395	9372

Ćwiczenie 2

Prawdopodobieństwo, że respondent używa środowiska Jupyter jeśli wiadomo, że używa Pythona

		Język programowania	
		Python	Inne
Środowisko	Jupyter	628	66
	Nie Jupyter	7395	9372

$$P(\text{Jupyter}|\text{Python}) = \frac{P(\text{Jupyter} \cap \text{Python})}{P(\text{Python})} = \frac{\frac{628}{17461}}{\frac{628 + 7395}{17461}} =$$

Ćwiczenie 2

Prawdopodobieństwo, że respondent używa środowiska Jupyter jeśli wiadomo, że używa Pythona

		Język programowania	
		Python	Inne
Środowisko	Jupyter	628	66
	Nie Jupyter	7395	9372

$$P(\text{Jupyter}|\text{Python}) = \frac{P(\text{Jupyter} \cap \text{Python})}{P(\text{Python})} = \frac{\frac{628}{\cancel{17461}}}{\frac{628 + 7395}{\cancel{17461}}} = \frac{628}{628 + 7395} = 0,078$$

Ćwiczenie 2

Prawdopodobieństwo, że respondent używa Pythona jeśli wiadomo, że używa środowiska Jupyter

		Język programowania	
		Python	Inne
Środowisko	Jupyter	628	66
	Nie Jupyter	7395	9372

Ćwiczenie 2

Prawdopodobieństwo, że respondent używa Pythona jeśli wiadomo, że używa środowiska Jupyter

		Język programowania	
		Python	Inne
Środowisko	Jupyter	628	66
	Nie Jupyter	7395	9372

$$P(\text{Python}|\text{Jupyter}) = \frac{P(\text{Jupyter} \cap \text{Python})}{P(\text{Jupyter})} = \frac{\frac{628}{17461}}{\frac{628 + 66}{17461}} =$$


Ćwiczenie 2

Prawdopodobieństwo, że respondent używa Pythona jeśli wiadomo, że używa środowiska Jupyter

		Język programowania	
		Python	Inne
Środowisko	Jupyter	628	66
	Nie Jupyter	7395	9372

$$P(\text{Python}|\text{Jupyter}) = \frac{P(\text{Jupyter} \cap \text{Python})}{P(\text{Jupyter})} = \frac{\frac{628}{\cancel{17461}}}{\frac{628 + 66}{\cancel{17461}}} = \frac{628}{628 + 66} = 0,905$$

Zupełny podział przestrzeni zdarzeń elementarnych




Zdarzenia $B_1, B_2, \dots, B_k$ tworzą podział przestrzeni zdarzeń elementarnych Ω (lub układ zupełny zdarzeń), jeżeli

$$B_i \cap B_j = \emptyset, \quad \text{gdy } i \neq j$$


oraz

$$B_1 \cup B_2 \cup \dots \cup B_k = \Omega$$

Zupełny podział przestrzeni zdarzeń elementarnych (przykład)




Prawdopodobieństwo zupełne



Jeżeli zdarzenia $B_1, B_2, \dots, B_k$ tworzą podział przestrzeni zdarzeń elementarnych Ω , prawdopodobieństwa zajścia każdego z nich są większe od zera $P(B_i) \neq 0$, dla $i = 1, 2, \dots, k$, to dla każdego zdarzenia $A \subset \Omega$.

$$P(A) = \sum_{i=1}^k P(A \cap B_i) = \sum_{i=1}^k P(A|B_i) \cdot P(B_i)$$

Prawdopodobieństwo zupełne (przykład)




Prawdopodobieństwo zupełne (przykład)

Pewna korporacja prowadzi działalność na trzech kontynentach w USA (Ameryka PN), w EU i w Azji.

Dla każdego rynku oszacowano, że prawdopodobieństwo zakupu subskrypcji rozważanej usługi przez losowego klienta wynosi 0,25, 0,7 oraz 0,5. Udział klientów na każdym z rynków wynosi odpowiednio 20%, 50% i 30%. Oblicz prawdopodobieństwo zakupu subskrypcji przez losowo wybranego klienta bez względu na lokalizację (A).

Prawdopodobieństwo zupełne (przykład)



Ω = klienci korporacji

Prawdopodobieństwo zupełne (przykład)

B_1 – USA, B_2 – EU, B_3 – Azji. A – zakup subskrypcji przez dowolnego klienta (niezależnie od położenia geograficznego).

$$P(A|B_1) = 0,25$$

$$P(A|B_2) = 0,7$$

$$P(A|B_3) = 0,5$$

$$P(B_1) = 0,2$$

$$P(B_2) = 0,5$$

$$P(B_3) = 0,3$$

$$\Sigma P(B_i) = 1,0$$

$$P(A) = \sum_{i=1}^k P(A|B_i) \cdot P(B_i) = 0,25 \cdot 0,2 + 0,7 \cdot 0,5 + 0,5 \cdot 0,3 = 0,55$$

Twierdzenie Bayesa

Jeżeli zdarzenia $B_1, B_2, \dots, B_k$ tworzą podział przestrzeni zdarzeń elementarnych Ω , prawdopodobieństwa zajścia każdego z nich są większe od zera $P(B_i) \neq 0$, dla $i = 1, 2, \dots, k$, to dla każdego zdarzenia $A \subset \Omega$, że $P(A) \neq 0$

$$P(B_m|A) = \frac{P(A|B_m) \cdot P(B_m)}{P(A)} = \frac{P(A|B_m) \cdot P(B_m)}{\sum_{j=1}^k P(A|B_j) \cdot P(B_j)}$$

Twierdzenie Bayesa (objaśnienie)

Twierdzenie Bayesa pozwala na aktualizację informacji (prawdopodobieństw różnych zdarzeń) w oparciu o nowe dowody np.:

- prawdopodobieństwo, że osoba jest stałym klientem $P(B_i)$
- prawdopodobieństwo, że osoba jest stałym klientem jeśli zalogowała się na konto sklepu (aktualizacja informacji) $P(B_i|A)$


Twierdzenie Bayesa (objaśnienie)

Twierdzenie Bayesa jest używane do określania możliwych przyczyn wystąpienia zjawisk: pewien stan wystąpił, jaka jest szansa, że jego przyczyną jest pewne wyszczególnione zdarzenie.

$$P(\text{przyczyna}_i | \text{stan}) = \frac{P(\text{stan} | \text{przyczyna}_i) \cdot P(\text{przyczyna}_i)}{P(\text{stan})}$$

Uwaga: określenie co jest stanem, a co przyczyną jest umowne, choć zwykle wynika z logicznego opisu problemu.

Twierdzenie Bayesa (objaśnienie)



Prawdopodobieństwo, że pacjent ma grypę $P(\text{grypa})$

Prawdopodobieństwo, że pacjent ma grypę, jeśli ma kaszel $P(\text{grypa}|\text{kaszel})$
(aktualizacja wiedzy – kaszel)

Twierdzenie Bayesa (objaśnienie 2)

Twierdzenie Bayesa jest używane do określania efektywności testów medycznych, algorytmów klasyfikujących itp. ponieważ możliwe jest wnioskowanie o zachowaniu testów w rzeczywistych przypadkach tj. uwzględnieniu proporcji np. osób chorych itp.

Twierdzenie Bayesa (przykład)

1 na 1000 klientów pewnego banku okazuje się być osobą nieuczciwą. Dział *fraud detection* tego banku opracował zestaw algorytmów poprawnie wykrywający oszusta z prawdopodobieństwem 0,99 (tzn. 99 na 100 oszustów udaje się wykryć). Niestety zdarza się, że system klasyfikuje osoby zupełnie uczciwe jako oszustów z prawdopodobieństwem 0,02 (2 na 100 uczciwych klientów jest niesłusznie oskarżonych). Oblicz prawdopodobieństwo, że osoba, którą system zaklasyfikował jako oszusta rzeczywiście jest nieuczciwa.

Twierdzenie Bayesa (przykład)

Oznaczmy: A – zaklasyfikowanie klienta jako oszusta,

B_1 – klient jest nieuczciwy, B_2 – klient jest uczciwy,

$A|B_1$ – klient został zaklasyfikowany jako oszust, jeśli jest nieuczciwy,

$A|B_2$ – klient został zaklasyfikowany jako oszust, jeśli jest uczciwy,

$B_1|A$ – klient jest nieuczciwy i został zaklasyfikowany jako oszust,

$B_2|A$ – klient jest uczciwy, a został zaklasyfikowany jako oszust.

$$P(B_1) = 0,001$$

$$P(B_2) = 0,999$$

$$P(A|B_1) = 0,99$$

$$P(A|B_2) = 0,02$$

$$P(B_1|A) = \frac{P(A|B_1)P(B_1)}{P(A|B_1)P(B_1) + P(A|B_2)P(B_2)} = 0,047$$

Twierdzenie Bayesa (przykład)

$B_1|A$ – klient jest rzeczywiście nieuczciwy, jeśli został zaklasyfikowany jako oszust,

$B_2|A$ – klient jest uczciwy, a został zaklasyfikowany jako oszust.

$$P(B_1) = 0,001$$

$$P(B_2) = 0,999$$

$$P(A|B_1) = 0,99$$

$$P(A|B_2) = 0,02$$

$$P(B_1|A) = 0,047$$

$$P(B_2|A) = 1 - P(B_1|A) = 0,953$$

Co to dokładnie oznacza?!

Twierdzenie Bayesa (przykład, interpretacja)

Jeżeli model skutecznie wykrywa 99% oszustów, a niesłusznie oskarża 2% uczciwych klientów, to przy średniej ilości nieuczciwych klientów wynoszącej 0,1%, aż 95,3% osób jest uczciwych mimo, że zostały zaklasyfikowane jako oszuści, a zaledwie 4,7% rzeczywiście okaże się oszustami jeśli system ich tak zaklasyfikował.

Czyli:

Jeśli bank zaklasyfikował klienta jako oszusta, istnieje 95,3% szans, że nie jest oszustem.

Jak temu zaradzić?

predykcja	obserwacja	
	uczciwy	oszust
	uczciwy	oszust
	97902	1
	1998	99
100000 - liczba analizowanych		
100 - liczba oszustów		
99900 - liczba uczciwych		

Nikt nigdy nie spyta Was o...

- prawdopodobieństwo warunkowe, że programista używa Pythona jeśli wiadomo, że używa Jupytera
- prawdopodobieństwo zupełne wylosowania kuli czarnej z jednej z urn, w których proporcje kul białych i czarnych wynoszą odpowiednio...
- prawdopodobieństwo Bayesa jeśli wiadomo, że...

Ale mogą zapytać o...

- ile osób (statystycznie rzecz biorąc) można natychmiast wdrożyć do projektów w Pythonie, skoro w naszych oddziałach raporty przygotowuje się używając głównie Jupytera
- na ile (statystycznie rzecz biorąc) klient jest skłonny kupić coś w naszym sklepie internetowym, skoro badania pokazały, że tyle i tyle osób dokonuje zakupów przy przekierowaniu z takiej a takiej strony, a tyle z takiej...
- czy opracowany właśnie test do wykrywania raka nadaje się do badań przesiewowych



Zmienna losowa


Definicja, własności, zastosowania

Zmienna losowa

Dowolną funkcję o wartościach rzeczywistych, określoną na zbiorze zdarzeń elementarnych Ω , nazywamy zmienną losową.

$$RV(\Omega) \rightarrow X$$

Zmienna losowa (objaśnienie)



Dana jest kostka sześcienna jak na rysunku (dwie ściany szare, cztery czerwone). Określ zmienną losową dla tego eksperymentu.

$$\Omega = \{ \bullet, \bullet \} \quad (\text{zdarzenia})$$



$$X = \{1, 2\} \quad (\text{liczby rzeczywiste})$$

(zmienna losowa)

Zmienna losowa (objaśnienie)

1. Zmienna losowa przyporządkowuje liczby rzeczywiste zdarzeniom;
2. Dowolnemu zdarzeniu z przestrzeni zdarzeń elementarnych Ω może zostać przyporządkowana dowolna liczba;
3. Zmienne losowe oznacza się zwykle wielkimi literami. Wartości osiągnane przez zmienne losowe oznaczane są małymi literami, np.:

$$P(X < x)$$

czyta się jako: „prawdopodobieństwo, że zmienna losowa X przyjmie wartość mniejszą niż x ”.

Rodzaje zmiennych losowych

Ze względu na typy wartości

- dyskretne
- ciągłe
- mieszane

Ze względu na ilość wymiarów

- jednowymiarowe
- wielowymiarowe

Prawdopodobieństwo przyjęcia wartości przez zmienną losową

Następujące zbiory zdarzeń elementarnych są zdarzeniami losowymi:

$$\{\omega: X(\omega) \in A\},$$

gdzie A jest zbiorem borelowskim na prostej, np.: $A=\{x_0\}$, $A=[a,b]$, $A=[x_0,+\infty)$, itp.

Prawdopodobieństwo, że zmienna losowa przyjmie wartość ze zbioru $A \in \mathbb{R}$ wynosi

$$P(X \in A) = P[\{\omega: X(\omega) \in A\}]$$

Dystrybuanta

Niech X będzie dowolną zmienną losową. Dystrybuantą zmiennej losowej X nazywa się funkcję F określoną dla dowolnego $x \in \mathbb{R}$, takiego że

$$F(x) = P(X \leq x)$$

Własności dystrybuanty:

1. Jest funkcją niemalejącą
2. $\lim_{x \rightarrow -\infty} F(x) = 0$; $\lim_{x \rightarrow \infty} F(x) = 1$
3. Jest przynajmniej lewostronnie ciągła

Zmienna losowa dyskretna

Zmienna losowa X jest dyskretna jeśli istnieje skończony lub przeliczalny zbiór $\Omega = \{x_1, \dots, x_n, \dots\}$ jej wartości $x_1, \dots, x_n, \dots$ takich, że

$$P(X = x_i) = p_i > 0, \quad i \in \mathbb{N}$$

$$\sum_{i=1}^{\infty} p_i = 1$$

Rozkład prawdopodobieństwa

Funkcję p określoną na zbiorze $\Omega = \{x_1, \dots, x_n, \dots\}$ następująco


$$p(x_i) = P(X = x_i) = p_i, \quad x_i \in \Omega$$

$$\sum_{i=1}^{\infty} p_i = 1$$

nazywa się funkcją rozkładu prawdopodobieństwa (masową funkcją prawdopodobieństwa).

Rozkład prawdopodobieństwa

x_i	x_1	x_2	...	x_n	...
p_i	p_1	p_2	...	p_n	...




Dystrybuanta dyskretnej zmiennej losowej

Dla dyskretnej zmiennej losowej, dystrybuanta $F(x) = P(X \leq x)$ przyjmuje postać

$$F(x) = P(X \leq x) = \sum_{x_i: x_i \leq x} p_i$$

Dystrybuanta dyskretnej zmiennej losowej

x_i	$(-\infty, x_1)$	$[x_1, x_2)$	$[x_2, x_3)$	...	$[x_{n-1}, x_n)$	...
$F(x)$	0	p_1	$p_1 + p_2$	...	$p_1 + p_2 + \dots + p_n$	...



Wartość oczekiwana zmiennej losowej dyskretnej

Wartość oczekiwana zmiennej losowej dyskretnej X , której rozkład prawdopodobieństwa to $p(x)$ jest następująco zdefiniowaną liczbą

$$E(X) = \mu_X = \sum_{i=1}^{\infty} x_i \cdot p(x_i)$$

Gdy Ω jest zbiorem skończonym to

$$E(X) = \mu_X = \sum_{i=1}^k x_i \cdot p(x_i)$$

Wariancja zmiennej losowej dyskretnej


Wariancją zmiennej losowej dyskretnej X , której rozkład prawdopodobieństwa to $p(x)$ jest następująco zdefiniowaną liczbą

$$V(X) = \sigma_X^2 = \sum_{i=1}^{\infty} (x_i - E(X))^2 \cdot p(x_i)$$

Gdy Ω jest zbiorem skończonym to

$$V(X) = \sigma_X^2 = \sum_{i=1}^k (x_i - E(X))^2 \cdot p(x_i)$$

Zmienna losowa dyskretna (przykład)



Ω						
$X(\omega_i)$	1	2	3	4	5	6
$p(x_i)$	1/6	1/6	1/6	1/6	1/6	1/6
$F(x_i)$	1/6	2/6	3/6	4/6	5/6	1

Wartość oczekiwana (przykład)



$X(\omega_i)$	1	2	3	4	5	6
$p(x_i)$	1/6	1/6	1/6	1/6	1/6	1/6

$$E(X) = \mu_X = \sum_{i=1}^6 x_i \cdot p(x_i) = 1 \cdot \frac{1}{6} + 2 \cdot \frac{1}{6} + \dots + 6 \cdot \frac{1}{6} = 3\frac{1}{2}$$

Wariancja (przykład)




$$E(X) = 3,5$$


$$V(X) = \sum_{i=1}^6 (x_i - E(X))^2 \cdot p(x_i) =$$

$$(1 - 3,5)^2 \cdot \frac{1}{6} + (2 - 3,5)^2 \cdot \frac{1}{6} + \dots + (6 - 3,5)^2 \cdot \frac{1}{6} = 2,917$$


Zmienna losowa dyskretna (przykład)



Ω		
$X(\omega_i)$	1	2
$p(x_i)$	4/6	2/6
$F(x_i)$	4/6	1




Wartość oczekiwana (przykład)



$X(\omega_i)$	1	2
$p(x_i)$	4/6	2/6

$$E(X) = \mu_X = \sum_{i=1}^2 x_i \cdot p(x_i) = 1 \cdot \frac{4}{6} + 2 \cdot \frac{2}{6} = \frac{4}{3}$$

Wariancja (przykład)



$X(\omega_i)$	1	2
$p(x_i)$	4/6	2/6

$$E(X) = \frac{4}{3}$$

$$V(X) = \sum_{i=1}^2 (x_i - E(X))^2 \cdot p(x_i) = \left(1 - \frac{4}{3}\right)^2 \cdot \frac{4}{6} + \left(2 - \frac{4}{3}\right)^2 \cdot \frac{2}{6} = \frac{2}{9}$$

Ćwiczenie 3



Znaleźć rozkład prawdopodobieństwa, dystrybuantę, wartość oczekiwaną i wariancję zmiennej losowej X – sumy oczek otrzymanej w wyniku rzutu dwiema kostkami do gry.

Zmienna losowa ciągła

Zmienną losową X nazywa się ciągłą, jeśli dla dowolnej nieujemnej funkcji f i dowolnych liczb rzeczywistych a i b , takich że $-\infty \leq a < b \leq \infty$, zachodzi

$$P(a \leq X \leq b) = \int_a^b f(t)dt$$

oraz

$$\int_{-\infty}^{\infty} f(t)dt = 1$$

Gęstość rozkładu prawdopodobieństwa

Dowolna nieujemna funkcja $f(x)$, gdzie $x \in \mathbb{R}$, dla której zachodzi

$$\int_{-\infty}^{\infty} f(t) dt = 1$$

jest gęstością rozkładu prawdopodobieństwa.

Dystrybuanta zmiennej losowej ciągłej

Dla ciągłej zmiennej losowej, dystrybuanta $F(x) = P(X \leq x)$ przyjmuje postać

$$F(x) = P(X \leq x) = \int_{-\infty}^x f(t)dt$$

zatem zachodzi również

$$F'(x) = f(x)$$


Obliczanie prawdopodobieństwa

$$P(a < X < b) = \int_a^b f(t)dt = F(b) - F(a)$$

$$P(X < a) = \int_{-\infty}^a f(t)dt = F(a)$$

$$P(X > a) = \int_a^{+\infty} f(t)dt = 1 - F(a)$$

Gęstość rozkładu i dystrybuanta



Wartość oczekiwana zmiennej losowej ciągłej

Wartość oczekiwana zmiennej losowej ciągłej X , której gęstość rozkładu prawdopodobieństwa to $f(x)$ jest następująco zdefiniowaną liczbą


$$E(X) = \mu_X = \int_{-\infty}^{\infty} x \cdot f(x) dx$$

Wariancja zmiennej losowej ciągłej

Wariancją zmiennej losowej ciągłej X , której rozkład prawdopodobieństwa to $f(x)$ jest następująco zdefiniowaną liczbą

$$V(X) = \sigma_X^2 = \int_{-\infty}^{\infty} (x - E(X))^2 \cdot f(x) dx$$

Wartość oczekiwana zmiennej losowej ciągłej (przykład)




Zmienna losowa X ma w przedziale $[0,1]$ ma gęstość rozkładu prawdopodobieństwa

$$f(x) = \frac{3}{4}(x^2 + 2x) \text{ i zero poza nim.}$$

$$E(X) = \int_{-\infty}^{\infty} x \cdot f(x) dx = \int_{-\infty}^0 x \cdot 0 dx + \int_0^1 x \cdot \frac{3}{4}(x^2 + 2x) dx + \int_1^{\infty} x \cdot 0 dx$$

$$\begin{aligned} 0 + \frac{3}{4} \int_0^1 (x^3 + 2x^2) dx + 0 &= \frac{3}{4} \left(\int_0^1 x^3 dx + 2 \int_0^1 x^2 dx \right) = \\ &= \frac{3}{4} \left(\left[\frac{1}{4} x^4 \right]_0^1 + 2 \left[\frac{1}{3} x^3 \right]_0^1 \right) = \frac{11}{16} \end{aligned}$$

Wariancja zmiennej losowej ciągłej (przykład)



Zmienna losowa X ma w przedziale $[0,1]$ ma gęstość rozkładu prawdopodobieństwa

$$f(x) = \frac{3}{4}(x^2 + 2x) \text{ i zero poza nim.}$$

$$E(X) = \frac{11}{16}$$

$$\begin{aligned} V(X) &= \int_{-\infty}^{\infty} (x - E(X))^2 \cdot f(x) dx \\ &= \int_0^1 \left(x - \frac{11}{16}\right)^2 \cdot \frac{3}{4} (x^2 + 2x) dx = \frac{67}{1280} \end{aligned}$$

Ćwiczenie 4

Zmienna losowa X ma rozkład normalny $N(125,15)$. W języku Python:

1. Utwórz instancję tego rozkładu;
2. Narysuj gęstość rozkładu prawdopodobieństwa i dystrybuantę w zakresie $[\mu - 4\sigma; \mu + 4\sigma]$;
3. Oblicz prawdopodobieństwo, że zmienna losowa osiągnie wartość z zakresu 130 do 145;
4. Oblicz wartość oczekiwaną;
5. Oblicz odchylenie standardowe tej zmiennej;
6. Oblicz kwantyl 0,25 tej zmiennej losowej.

Ćwiczenie 5*

Zmienna losowa X ma w przedziale $[0,1]$ ma gęstość rozkładu prawdopodobieństwa $f(x) = \frac{3}{4}(x^2 + 2x)$ i zero poza nim. W języku Python zdefiniować rozkład prawdopodobieństwa, obliczyć wartość oczekiwaną i wariancję.



Podstawowe charakterystyki zmiennej losowej

Charakterystyki zmiennej losowej

Opisują położenie, rozproszenie, kształt i asymetrię zmiennej losowej.

Większość parametrów opisujących zmienną losową jest momentem lub kombinacją momentów zmiennej losowej.

Moment zwykły zmiennej losowej

Momentem zwykłym rzędu k zmiennej losowej X nazywamy liczbę

$$m_k = E(X^k)$$

Wartość oczekiwana jest momentem zwykłym rzędu pierwszego: $E(X) = m_1$.

Moment centralny zmiennej losowej

Momentem centralnym rzędu k zmiennej losowej X nazywamy liczbę

$$\mu_k = E\left((X - E(X))^k\right) = E\left((X - m_1)^k\right)$$

Moment centralny rzędu drugiego zawsze jest równy zeru.

Wariancja jest momentem centralnym rzędu drugiego: $V(X) = \mu_2$.

Moment dyskretnej zmiennej losowej

Moment zwykły:

$$m_k = E(X^k) = \sum_{x \in \mathbb{R}} p(x_i) \cdot x_i^k$$

Moment centralny:

$$\mu_k = E((X - m_1)^k) = \sum_{x \in \mathbb{R}} p(x_i) \cdot (x_i - m_1)^k$$

Moment dyskretnej zmiennej losowej (przykład)

x	0	3	4
$p(x)$	0,7	0,2	0,1

Dana jest zmienna losowa dyskretna X o rozkładzie prawdopodobieństwa przedstawionym w tabeli. Znajdź jej momenty zwykłe i centralne pierwszego i drugiego rzędu.

$$m_1 = E(X) = \sum_{x \in \mathbb{R}} p(x_i) \cdot x_i = 0,7 \cdot 0 + 0,2 \cdot 3 + 0,1 \cdot 4 = 1$$

$$m_2 = E(X^2) = \sum_{x \in \mathbb{R}} p(x_i) \cdot x_i^2 = 0,7 \cdot 0^2 + 0,2 \cdot 3^2 + 0,1 \cdot 4^2 = 3,4$$

Moment dyskretnej zmiennej losowej (przykład)

x	0	3	4
$p(x)$	0,7	0,2	0,1

Dana jest zmienna losowa dyskretna X o rozkładzie prawdopodobieństwa przedstawionym w tabeli. Znajdź jej momenty zwykłe i centralne pierwszego i drugiego rzędu.

$$\mu_1 = E(X - m_1) = \sum_{x \in \mathbb{R}} p(x_i) \cdot (x_i - m_1) = 0,7 \cdot (0 - 1) + 0,2 \cdot (3 - 1) + 0,1 \cdot (4 - 1) = 0$$

$$\mu_2 = E(X - m_1)^2 = \sum_{x \in \mathbb{R}} p(x_i) \cdot (x_i - m_1)^2 = 0,7 \cdot (0 - 1)^2 + 0,2 \cdot (3 - 1)^2 + 0,1 \cdot (4 - 1)^2 = 2,4$$

Moment ciągłej zmiennej losowej

Moment zwykły:

$$m_k = E(X^k) = \int_{-\infty}^{\infty} x^k \cdot f(x) dx$$

Moment centralny:

$$\mu_k = E\left((X - m_1)^k\right) = \int_{-\infty}^{\infty} (x - m_1)^k \cdot f(x) dx$$

Parametry położenia

Charakterystyczne wielkości związane z położeniem rozkładu, np.:

- wartość oczekiwana
- kwantyle (w tym kwartyle, percentyle, itd.)
- moda
- ...

Kwantyl

Kwantylem rzędu p ($0 < p < 1$) zmiennej losowej X , której dystrybuantą jest funkcja F jest taka liczba x_p , dla której zachodzi


$$F([x_p]^-) \leq p \leq F([x_p]^+)$$

Kwantyl rzędu p dzieli rozkład prawdopodobieństwa w stosunku $p:1-p$


Mediana jest kwantylem rzędu 0,5.

Kwartyle są kwantylami rzędu 0,25, 0,5 i 0,75

Kwantyl (przykład)



Kwantyl (przykład)



Moda

Wartość zmiennej losowej, dla której funkcja rozkładu lub funkcja gęstości rozkładu prawdopodobieństwa jest największa.

Moda jest wartością o największym prawdopodobieństwie wystąpienia.
Rozkład może nie mieć mody lub mieć ich wiele.

Parametry rozproszenia

Charakterystyczne wielkości związane rozrzutem wartości przyjmowanych przez zmienną losową.:

- wariancja / odchylenie standardowe
- odchylenie przeciętne
- rozstęp
- rozstęp międzykwartyłowy
- ...

Odchylenie przeciętne

Odchyleniem przeciętnym zmiennej losowej X nazywamy wartość

$$d_1 = E(|X - E(X)|)$$

Odchylenie przeciętne zmiennej losowej dyskretnej

Odchyleniem przeciętnym dyskretnej zmiennej losowej X nazywamy wartość

$$d_1 = \sum_{i=1}^{\infty} |(x_i - E(X))| \cdot p(x_i)$$

Jeśli Ω jest zbiorem skończonym zawierającym k elementów

$$d_1 = \sum_{i=1}^k |(x_i - E(X))| \cdot p(x_i)$$

Odchylenie przeciętne zmiennej losowej ciągłej

Odchyleniem przeciętnym ciągłej zmiennej losowej X nazywamy wartość

$$d_1 = \int_{-\infty}^{\infty} |x - E(X)| \cdot f(x) dx$$

Parametry kształtu

Charakterystyczne wielkości związane z położeniem rozkładu, np.:


- kurtoza
- współczynnik asymetrii
- ...



Model statystyczny

A gdzie tu statystyka?

Model statystyczny



Statystyczna analiza danych

Zebrane dane charakteryzuje się parametrami identycznymi jak te używane do charakteryzowania rozkładów, np.:

- wartość oczekiwana (średnia)
- odchylenie standardowe
- kwantyle (mediana, IQR)
- rozstęp

Skąd się biorą teoretyczne rozkłady
prawdopodobieństwa?


???

A solid purple vertical bar is positioned on the left side of the slide.

**Czy data scientist potrzebuje
teoretycznych rozkładów
prawdopodobieństwa opisujących
rzeczywiste zjawiska?**

???

Rozkład ilości punktów na egzaminie maturalnym w 2010 r.



Wykres 1. Rozkład wyników na poziomie podstawowym

źródło: www.cke.edu.pl



Literatura

- **Statystyka matematyczna. Modele i zadania.** Wydanie IV. **Greń J.**, PWN 1974
- Rachunek prawdopodobieństwa i statystyka matematyczna w zadaniach. Krysicki W., Bartos J., Dyczka W., Królikowska K., Wasilewski M., PWN 1997
- Statystyka dla kierunków technicznych i przyrodniczych. J. Koronacki, J. Mielniczuk, WNT 2006

Literatura

- Metody i narzędzia eksploracji danych.
Osowski S., BTC 2013
- The Elements of Statistical Learning ([link to pdf](#))
Data Mining, Inference, and Prediction
Hastie T., Tibshirani R., Friedman J.


Podstawowe biblioteki

- scipy (moduł scipy.stats)
- stasmodels



Przykłady rozkładów

Rozkład dwupunktowy



Niech przestrzenią zdarzeń elementarnych będzie

$$\Omega = \{\omega_1, \omega_2\}$$

dziedziną zmiennej losowej

$$D = \{x_1, x_2\}$$

oraz


$$P(\omega: X(\omega) = x_1) = p$$

$$P(\omega: X(\omega) = x_2) = 1 - p$$

gdzie

$$0 < p < 1$$

Rozkład jednostajny



Niech przestrzenią zdarzeń elementarnych będzie

$$\Omega = \{\omega_1, \omega_2, \dots, \omega_k\}$$

dziedziną zmiennej losowej

$$D = \{x_1, x_2, \dots, x_k\}$$


oraz

$$P(\{\omega: X(\omega) = x_k, k = 1, 2, \dots, N\}) = p = \frac{1}{N}$$

Rozkład dwumianowy


Zakładając schemat losowania zgodny ze schematem Bernoullego, prawdopodobieństwo zajścia k razy zdarzenia A w n próbach równe jest:

$$p_n(k) = \binom{n}{k} \cdot p^k \cdot q^{n-k}$$




Rozkład geometryczny

Zakładając schemat losowania zgodny ze schematem Bernoullego, prawdopodobieństwo zajścia zdarzenia A pierwszy raz w k -tej próbie równe jest:



Rozkład Poissona




Zakładając schemat losowania zgodny ze schematem Bernoullego, mówimy, że zmienna losowa ma *rozkład Poissona*, jeśli

$$D = \{0, 1, 2, \dots\}$$

$$p(k) = \frac{e^{-\lambda} \cdot \lambda^k}{k!}$$

$$\lambda = n \cdot p > 0, \quad k = 0, 1, 2, \dots$$


Ciągły rozkład jednostajny



Zmienna losowa X , ma rozkład jednostajny (prostokątny, równomierny) w przedziale $[a, b]$ jeśli jego gęstość opisana jest wzorem

$$f(x) = \begin{cases} 0 & \text{dla } x < a \\ \frac{1}{b-a} & \text{dla } a \leq x \leq b \\ 0 & \text{dla } x > b \end{cases}$$

Rozkład normalny



Zmienna losowa X , ma rozkład normalny o parametrach μ i $\sigma > 0$ jeśli jej gęstość prawdopodobieństwa opisana jest wzorem


$$f(x) = \frac{1}{\sigma \cdot \sqrt{2 \cdot \pi}} \cdot e^{\left(-\frac{1}{2} \left(\frac{x - \mu}{\sigma} \right)^2 \right)}$$

gdzie:

μ – parametr położenia,

σ – parametr rozproszenia.

Rozkład gamma



Zmienna losowa X , ma uogólniony rozkład gamma o parametrach $\alpha > 0$, $\beta > 0$, $\gamma > 0$ i $\mu \in \mathbb{R}$ jeśli jej gęstość prawdopodobieństwa opisana jest wzorem


$$f(x) = \begin{cases} 0 & \text{dla } x \leq \mu \\ \frac{\gamma \cdot \left(\frac{x-\mu}{\beta}\right)^{\alpha \cdot \gamma - 1}}{\beta \cdot \Gamma(\alpha)} \cdot e^{-\left(\frac{x-\mu}{\beta}\right)^{\gamma}} & \text{dla } x > \mu \end{cases}$$

gdzie:

$$\Gamma(\alpha) = \int_0^{\infty} x^{\alpha-1} \cdot e^{-x} dx$$

α , γ – parametry kształtu,
 β – parametr skalujący,
 μ – parametr położenia.

Rozkład gamma



Zmienna losowa X , ma uogólniony rozkład gamma o parametrach $\alpha > 0$, $\beta > 0$, $\gamma > 0$ i $\mu \in \mathbb{R}$ jeśli jej gęstość prawdopodobieństwa opisana jest wzorem


$$f(x) = \begin{cases} 0 & \text{dla } x \leq \mu \\ \frac{\gamma \cdot \left(\frac{x-\mu}{\beta}\right)^{\alpha \cdot \gamma - 1}}{\beta \cdot \Gamma(\alpha)} \cdot e^{-\left(\frac{x-\mu}{\beta}\right)^\gamma} & \text{dla } x > \mu \end{cases}$$

gdzie:

$$\Gamma(\alpha) = \int_0^{\infty} x^{\alpha-1} \cdot e^{-x} dx$$

α, γ – parametry kształtu,
 β – parametr skalujący,
 μ – parametr położenia.

Rozkład beta




Zmienna losowa X , ma rozkład beta o parametrach $\alpha > 0$, $\beta > 0$ jeśli jej gęstość prawdopodobieństwa opisana jest wzorem

$$f(x) = \begin{cases} 0 & \text{dla } x \notin (0,1) \\ \frac{1}{B(\alpha, \beta)} \cdot x^{\alpha-1} \cdot (1-x)^{\beta-1} & \text{dla } x \in (0,1) \end{cases}$$

gdzie

$$B(\alpha, \beta) = \frac{\Gamma(\alpha) \cdot \Gamma(\beta)}{\Gamma(\alpha + \beta)}$$

Rozkład beta




Zmienna losowa X , ma rozkład beta o parametrach $\alpha > 0$, $\beta > 0$ jeśli jej gęstość prawdopodobieństwa opisana jest wzorem

$$f(x) = \begin{cases} 0 & \text{dla } x \notin (0,1) \\ \frac{1}{B(\alpha, \beta)} \cdot x^{\alpha-1} \cdot (1-x)^{\beta-1} & \text{dla } x \in (0,1) \end{cases}$$

gdzie

$$B(\alpha, \beta) = \frac{\Gamma(\alpha) \cdot \Gamma(\beta)}{\Gamma(\alpha + \beta)}$$

Rozkład wykładniczy



Zmienna losowa X , ma rozkład wykładniczy o parametrze λ jeśli jej gęstość prawdopodobieństwa opisana jest wzorem

$$f(x) = \begin{cases} 0 & \text{dla } x < 0 \\ \lambda \cdot e^{-\lambda \cdot x} & \text{dla } x > 0 \end{cases}$$

Dzięki za uwagę

infoShareAcademy.com