

Statystyka opisowa Junior Data Scientist

infoShare Academy



HELLO

Wojciech Artichowicz





01. Terminy podstawowe


Próba losowa

Próba losowa $\{x_1, x_2, \dots, x_n\}$ jest zbiorem realizacji zmiennej losowej X , to jest n -elementowym podzbiorem zbioru X .

Istnieje wiele różnych możliwych n -elementowych podzbiorów, czyli może być wiele różnych wartości $x_1, x_2, \dots, x_n$. Fakt ten zapisuje się jako $(X_1, X_2, \dots, X_n)$.

Próba jest zatem n -elementowym zbiorem realizacji zmiennych losowych, mających taki sam rozkład.

Próba losowa



Próba losowa (przykład)



Dwukrotnie przeprowadzono eksperyment polegający na trzykrotnym rzucie sześcienną kostką do gry. Każdej ze ścian kostki przyporządkowano liczbę odpowiadającą ilości oczek na tej ścianie. Otrzymano następujące wyniki:

Próba I: {2, 6, 1}

Próba II: {4, 5, 4}

Każdą wielkość Z_n będącą funkcją próby losowej $(X_1, X_2, \dots, X_n)$ nazywa się statystyką.

Każda statystyka jest zmienną losową ponieważ jest funkcją zmiennej losowej i posiada rozkład prawdopodobieństwa.

Statystyka (przykład)

Dana jest próba losowa będąca wynikiem oceny aplikacji w sklepie Google Play (liczba gwiazdek 1÷5):

$$x = \{5, 1, 5, 2, 2, 1, 5, 5, 2, 1\}$$

Estymatorem wartości oczekiwanej w próbie jest średnia arytmetyczna, która jest funkcją próby:

$$\bar{x} = f(x) = \frac{1}{n} \sum_{i=1}^n x_i$$
$$\bar{x} = \frac{5 + 1 + 5 + 2 + 2 + 1 + 5 + 5 + 2 + 1}{10} = 2,9$$



02. Statystyka opisowa

Statystyka opisowa

Statystyka opisowa zajmuje się wstępnym opisem próby oraz badaniem takich własności rozkładów jak parametry położenia, dyspersji i kształtu.

Jednym z najważniejszych elementów statystyki opisowej jest graficzna prezentacja danych.

Próba mała

Próba jest mała jeśli do wyznaczenia statystyki Z_n konieczne jest użycie dokładnego rozkładu populacji generalnej.

Próba duża

Próba jest duża jeśli do wyznaczenia statystyki Z_n nie jest konieczne jest użycie dokładnego rozkładu populacji generalnej.

Wnioskowanie na temat statystyki można oprzeć na twierdzeniach rachunku prawdopodobieństwa, np.: w celu wnioskowania o średniej populacji generalnej można skorzystać z centralnego twierdzenia granicznego.

Rozkład graniczny


Gdy liczebność próby n zmierza do nieskończoności to rozkład statystyki Z_n nazywamy rozkładem granicznym.

Ćwiczenie 1

Zbadaj zbieżność rozkładu T-Studenta do rozkładu normalnego.

Rozkład graniczny (przykład)

Różnica między średnią w populacji generalnej, a średnią z próby podlega rozkładowi t -Studenta. Dla dużych wartości n rozkład t -Studenta staje się identyczny z rozkładem normalnym standardowym.



Szeregi statystyczne

Szereg statystyczny – uporządkowany lub uporządkowany i pogrupowany materiał statystyczny według wariantów cechy.

Szereg szczegółowy (wyliczający) – uporządkowany materiał, ale nie pogrupowany (zawiera wszystkie zebrane dane).

Szereg rozdzielczy – szereg, w którym próba została rozdzielona na części według określonych wariantów cechy.

Szeregi statystyczne

Szereg strukturalny – dane pogrupowane według cechy jakościowej.

Szereg punktowy – dane pogrupowane według cechy ilościowej.

Szereg przedziałowy – dane pogrupowane według cechy ilościowej, której warianty zostały sklasyfikowane w formie przedziałów.

Szereg strukturalny

Sales by category and time period				
year	month	category		
		A	B	C
2017	January	10	92	86
	February	25	1	78
	March	48	13	95
	April	69	72	53
	May	14	26	42
	June	39	61	72
	July	92	100	47
	August	13	83	70
	September	16	1	67
	October	88	78	69
	November	20	27	15
	December	81	18	79

Szereg przedziałowy

j	$X_{p,j} - X_{k,j}$	X_{si}	n_j
1	[-6.29231 ; -5.83432)	-6.06331	2
2	[-5.83432 ; -5.37634)	-5.60533	0
3	[-5.37634 ; -4.91835)	-5.14734	4
4	[-4.91835 ; -4.46037)	-4.68936	1
5	[-4.46037 ; -4.00238)	-4.23137	8
6	[-4.00238 ; -3.5444)	-3.77339	6
7	[-3.5444 ; -3.08641)	-3.3154	7
8	[-3.08641 ; -2.62843)	-2.85742	22
9	[-2.62843 ; -2.17044)	-2.39944	20
10	[-2.17044 ; -1.71246)	-1.94145	50

Częstość

Częstość – liczebność względna, prawdopodobieństwo empiryczne, stosunek liczności danej kategorii odniesiona do sumy obserwacji.

$$p_i = \frac{n_i}{n}$$

i	x_i	n_i
1	1-3	3
2	4-6	5
3	7-9	7
4	10-12	3
5	14-18	1
Razem (n)		19

Wskaźniki próby

Są to odpowiedniki parametrów wyrażających własności teoretycznych rozkładów prawdopodobieństwa np. wartość oczekiwana próby, wariancja próby itp.:

- parametry położenia
- parametry rozproszenia
- parametry kształtu
- ...

Wskaźniki położenia

Określają położenie rozkładu.

- Średnia (arytmetyczna, harmoniczna, geometryczna)
- Kwantyle
- Moda

Średnia arytmetyczna

Wartością średnią próby, oznaczaną $\bar{x}$ nazywamy średnią arytmetyczną w próbie

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Dla szeregu rozdzielczego

$$\bar{x} = \frac{1}{n} \sum_{i=1}^k x_{s,i} \cdot n_i$$

k – liczba klas, $x_{s,i}$ - wartość środka klasy, n_i - liczebność klasy

Średnia arytmetyczna (przykład)

i	x
1	1,98
2	0,17
3	2,76
4	2,41
5	0,04
6	3,56
7	0,94
8	0,67
9	3,19
10	3,89

$$\bar{x} = \frac{1,98 + 0,17 + \dots + 3,19 + 3,89}{10} = 1,961$$

Średnia arytmetyczna (przykład)

i	x_i	$x_{s,i}$	n_i
1	1-3	2	3
2	4-6	5	5
3	7-9	8	7
4	10-12	11	3
5	14-18	16	1
Razem (n)			19

$$\begin{aligned}\bar{x} &= \frac{1}{n} \sum_{i=1}^k x_{s,i} \cdot n_i = \\ &= \frac{2 \cdot 3 + 5 \cdot 5 + 8 \cdot 7 + 11 \cdot 3 + 16 \cdot 1}{19} = 7,2\end{aligned}$$

Średnia geometryczna

Średnią geometryczną w próbie nazywamy liczbę

$$\bar{x}_G = \sqrt[n]{x_1 \cdot x_2 \cdots x_n}$$

Dla szeregu rozdzielczego

$$\bar{x}_G = \exp \left(\frac{\sum_{i=1}^k n_i \cdot \ln(x_{s,i})}{\sum_{i=1}^k n_i} \right)$$

(średnia geometryczna jest mniej wrażliwa na obserwacje odstające)

Średnia geometryczna (przykład)

i	x
1	1,98
2	0,17
3	2,76
4	2,41
5	0,04
6	3,56
7	0,94
8	0,67
9	3,19
10	3,89

$$\bar{x}_G = \sqrt[10]{1,98 \cdot 0,17 \cdots 3,19 \cdot 3,89} = 1,096$$

Średnia geometryczna (przykład)

i	x_i	$x_{s,i}$	n_i
1	1-3	2	3
2	4-6	5	5
3	7-9	8	7
4	10-12	11	3
5	14-18	16	1
Razem (n)			19

$$\bar{x}_G = \exp\left(\frac{3 \cdot \ln(2) + 5 \cdot \ln(5) + \dots + 1 \cdot \ln(16)}{19}\right) = 6,194$$

Średnia harmoniczna

Średnią harmoniczną w próbie nazywamy liczbę

$$\bar{x}_H = \frac{n}{\sum_i^n \frac{1}{x_i}}$$

Dla szeregu rozdzielczego

$$\bar{x}_H = \frac{n}{\sum_i^k \frac{n_i}{x_i}}$$

Średnia harmoniczna (przykład)

i	x
1	1,98
2	0,17
3	2,76
4	2,41
5	0,04
6	3,56
7	0,94
8	0,67
9	3,19
10	3,89

$$\bar{x}_H = \frac{10}{\frac{1}{1,98} + \frac{1}{0,17} + \dots + \frac{1}{3,19} + \frac{1}{3,89}} = 0,28$$

Średnia harmoniczna (przykład)

i	x_i	$x_{s,i}$	n_i
1	1-3	2	3
2	4-6	5	5
3	7-9	8	7
4	10-12	11	3
5	14-18	16	1
Razem (n)			19

$$\bar{x}_H = \frac{19}{\frac{3}{2} + \frac{5}{5} + \frac{7}{8} + \frac{3}{11} + \frac{1}{16}} = 5,12$$

Kwantyle (statystyki pozycyjne)

Kwantyl rzędu p jest statystyką pozycyjną, która dzieli uporządkowaną próbę na podzbiory, których licznosci pozostają w stosunku $p:1-p$.

Mediana jest kwantylem dzielącym próbę na dwie połowy:

$$Me = \begin{cases} x_{(n+1)/2} & \text{gdy } n \text{ nieparzyste} \\ \frac{1}{2}(x_{n/2} + x_{(n/2+1)}) & \text{gdy } n \text{ parzyste} \end{cases}$$

Kwantyle (przykład)

Dla podanej próby określ kwantyle rzędu 0,15 i 0,7.

i	$x_{\downarrow}$
1	0,04
2	0,17
3	0,67
4	0,94
5	1,98
6	2,41
7	2,76
8	3,19
9	3,56
10	3,89

← $i_{q_{0,15}}$

$$i_{q_{0,15}} = n \cdot p = 10 \cdot 0.15 = 1.5$$

$$q_{0,15} = \frac{x_1 + x_2}{2} = \frac{0,04 + 0,17}{2} = 0,105$$

← $i_{q_{0,7}}$

$$i_{q_{0,7}} = n \cdot p = 10 \cdot 0.7 = 7$$

$$q_{0,7} = x_7 = 2,76$$

Kwantyle (przykład)

Dla podanej próby określ medianę.

i	$x_{\downarrow}$
1	0,04
2	0,17
3	0,67
4	0,94
5	1,98
6	2,41
7	2,76
8	3,19
9	3,56
10	3,89

$$i_{q_{0,5}} = n \cdot p = 10 \cdot 0,15 = 1,5$$

$$Me = q_{0,5} = \frac{x_4 + x_5}{2} = \frac{0,94 + 1,98}{2} = 1,46$$

← $i_{q_{0,5}}$

Moda (średnia częstościowa)

Moda jest wartością występującą w próbie (skala porządkowa).

W przypadku zmiennej ciągłej modę wyznacza się ze wzoru

$$Mo = x_{i,0} + \frac{n_i - n_{i-1}}{(n_i - n_{i-1}) + (n_i - n_{i+1})} h_i$$

gdzie:


i – indeks najliczniejszej klasy,

$x_{i,0}$ - dolna granica najliczniejszej klasy



h_i - szerokość najliczniejszej klasy

n_i - liczba elementów w i -tej klasie..



Moda (średnia częstościowa)



Rozkłady jednomodalne



Rozkłady wielomodalne





Wskaźniki rozproszenia

Określają stopień rozproszenia rozkładu

Wariancja

Wariancja jest średnią z kwadratów odchylek od średniej arytmetycznej

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

Dla szeregu rozdzielczego

$$s^2 = \frac{n}{n^2 - \sum_{i=1}^k n_i^2} \sum_{i=1}^k n_i (x_{s,i} - \bar{x})^2$$

Wariancja (przykład)

i	x
1	1,98
2	0,17
3	2,76
4	2,41
5	0,04
6	3,56
7	0,94
8	0,67
9	3,19
10	3,89

$$\bar{x} = 1,961$$

$$s^2 = \frac{1}{10 - 1} ((1,98 - 1,961)^2 + (0,17 - 1,961)^2 + \dots + (3,19 - 1,961)^2 + (3,89 - 1,961)^2) = 2,026$$

Wariancja (przykład)

i	x_i	$x_{s,i}$	n_i
1	1-3	2	3
2	4-6	5	5
3	7-9	8	7
4	10-12	11	3
5	14-18	16	1
Razem (n)			19

$$\bar{x} = 7,2$$

$$s^2 = \frac{n}{n^2 - \sum_{i=1}^k n_i^2} \sum_{i=1}^k n_i (x_{s,i} - \bar{x})^2 =$$

$$s^2 = \frac{19}{19^2 - 93} (3 \cdot (2 - 7,2)^2 + 5 \cdot (5 - 7,2)^2 + \\ + 7 \cdot (8 - 7,2)^2 + 3 \cdot (11 - 7,2)^2 + 1 \cdot (16 - 7,2)^2) = \\ 16,43$$


Odchylenie standardowe

Odchylenie standardowe jest pierwiastkiem z wariancji


$$s = \sqrt{s^2}$$

W przypadku rodziny rozkładów normalnych odchylenie standardowe dobrze odzwierciedla rozproszenie typowych obserwacji od średniej. W przedziale $\bar{x} \pm s$ znajduje się 68,2% najbardziej charakterystycznych obserwacji. Zależność taka nie musi dotyczyć prób pochodzących z innych rozkładów.


Reguła 3σ



Odchylenie standardowe - komentarz



Odchylenie standardowe - komentarz



W przypadku rozkładów z rodzin innych niż normalne odchylenie standardowe może nie być dobrą miarą określającą zakres typowych jednostek.

Odchylenie przeciętne

Odchylenie przeciętne jest dane wzorem

$$d_1 = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|$$

Dla szeregu rozdzielczego

$$d_1 = \frac{1}{n} \sum_{i=1}^k n_i \cdot |x_{s,i} - \bar{x}|$$

Rozstęp

Rozstęp jest różnicą wartości największej i najmniejszej.

$$R = x_{max} - x_{min}$$


Rozstęp międzykwartylowy

Rozstęp międzykwartylowy (IQR) jest różnicą kwantyla rzędu 0,75 (kwartyla trzeciego) i kwantyla rzędu 0,25 (kwartyla pierwszego)


$$IQR = q_{0,75} - q_{0,25}$$

Między wartościami $q_{0,25}$ oraz $q_{0,75}$ mieści się 50% wszystkich elementów próby. Zatem IQR jest zakresem tych wartości.

Rozstęp międzykwartylowy



Rozstęp międzykwartylowy



Odchylenie ćwiartkowe

Odchylenie ćwiartkowe jest połową odchylenia międzykwartylowego

$$Q = \frac{IQR}{2}$$

Parametry kształtu

Określają symetrię i skupienie rozkładu

- miary asymetrii

- współczynnik asymetrii $A = \frac{\bar{x} - D}{s}$

- współczynnik skośności $A_q = \frac{(q_{0.75} - Me) - (Me - q_{0.25})}{q_{0.75} - q_{0.25}}$

- miary skupienia

- miary spłaszczenia

Momenty z próby

Moment zwykły

$$m_k = \frac{1}{n} \sum_{i=1}^n x^k$$

Moment centralny

$$\mu_k = \frac{1}{n} \sum_{i=1}^n (x - \bar{x})^k$$

Ćwiczenie 2


Dla danej próby $x = \{9,0; 12,0; 5,0; 0,23; 1,3; 5,5; 8,11; 3,33; 2,1; 6,32\}$

oblicz podstawowe charakterystyki:

- miary tendencji centralnej: średnią arytmetyczną, geometryczną i harmoniczną oraz medianę
- miary dyspersji: odchylenie standardowe i średnie odchylenie przeciętne, rozstęp, rozstęp kwartyłowy

Szeregi czasowe

Badanie wartości zjawiska w ustalonych momentach czasu.



Średnia chronologiczna

Średnia wartość badanej wielkości z określonych momentów czasu

$$\bar{y}_{ch} = \frac{\frac{1}{2}y_1 + y_2 + \dots + y_{n-1} + \frac{1}{2}y_n}{n - 1}$$

n – liczba momentów, w których badano zjawisko,

$y_1, y_2, \dots$ - wielkości badanego zjawiska.

Wskaźniki dynamiki (indeksy)

Służą do określania relatywnych zmian w szeregach czasowych.

Zwykle określają zmianę względem okresu bazowego, lub poprzedzającego dany okres.

Indeksy jednopodstawowe

Przyjmują za podstawę porównania stałą wartość (zwykle pierwszą z badanego okresu)

$$I_{j/0} = \frac{y_j}{y_0} \cdot 100\%$$

Indeksy łańcuchowe

Przyjmują za podstawę porównania wartość z poprzedniego momentu

$$I_{j/j-1} = \frac{y_j}{y_{j-1}} \cdot 100\%$$

Względny przyrost łańcuchowy (tempo)

Wyraża stosunek przyrostu absolutnego do wielkości badanego zjawiska z poprzedniego momentu

$$T_j = \frac{y_j - y_{j-1}}{y_{j-1}} \cdot 100\%$$



03. Statystyczna wizualizacja

Wykres skrzynkowy, gęstości, histogram.


Histogram

Histogram to nieparametryczny estymator gęstości rozkładu prawdopodobieństwa w populacji generalnej.


Histogram konstruuje się na podstawie szeregu rozdzielczego.

Histogram


i	$[x_{i,d}; x_{i,g})$	n_i	$p_i = \frac{n_i}{N}$	$f_i = \frac{p_i}{h_i}$
1	$[x_{1,d}; x_{1,g})$	n_1	$p_1 = \frac{n_1}{N}$	$f_1 = \frac{p_1}{h_1}$
2	$[x_{2,d}; x_{2,g})$	n_2	$p_2 = \frac{n_2}{N}$	$f_2 = \frac{p_2}{h_2}$
...	...	...	...	...
k	$[x_{k,d}; x_{k,g}]$	n_k	$p_k = \frac{n_k}{N}$	$f_k = \frac{p_k}{h_k}$




Histogram vs. populacja generalna



Wpływ szerokości klasy histogramu



Określenie liczby klas



$$h = \frac{R}{k} = \frac{x_{\max} - x_{\min}}{k}$$


$$k = \lceil \sqrt{n} \rceil \quad - \text{metoda pierwiastka kwadratowego}$$

$$k = \lceil \log_2 n + 1 \rceil \quad - \text{metoda Struges}$$

$$k = \lceil 2\sqrt[3]{n} \rceil \quad - \text{metoda Rice}$$

$$k = \log_2 n + \log_2 \left(1 + \frac{|\mu_3|}{\sqrt{\frac{6(n-2)}{(n+1)(n+3)}}} \right) + 1 \quad - \text{metoda Doanesa}$$

Określenie szerokości klas



$$k = \left\lceil \frac{R}{h} \right\rceil = \left\lceil \frac{x_{\max} - x_{\min}}{h} \right\rceil$$

$$h = \frac{2,64 \cdot IQR}{\sqrt[3]{n}} \quad - \text{metoda półempiryczna dla rodziny rozkładów normalnych}$$

$$\min_h \frac{2}{(n-1)h} - \frac{n+1}{n^2(n-1)h} \sum_k n_k^2 \quad - \text{metoda Scotta dla dowolnych rozkładów}$$

$$h = \frac{3,5 \cdot s}{\sqrt[3]{n}} \quad - \text{metoda Scotta dla rodziny rozkładów normalnych}$$

$$h = \frac{2 \cdot IQR}{\sqrt[3]{n}} \quad - \text{metoda Freedmana-Diaconisa}$$

Jądrowy estymator gęstości prawdopodobieństwa

Jądrowa estymacja gęstości prawdopodobieństwa polega na przyporządkowaniu każdemu punktowi w próbie jądra i zsumowaniu wartości osiąganych przez funkcje jądrowe w danym punkcie x .

$$\hat{f}(x) = \frac{1}{N \cdot h} \sum_{i=1}^n K\left(\frac{x-x_i}{h}\right)$$


gdzie $K(x)$ jest funkcją jądrową

$$\int_{-\infty}^{\infty} K(x) dx = 1$$

h – parametr wygładzania (analogia szerokości klasy histogramu).


Jądrowy estymator gęstości prawdopodobieństwa

$$\hat{f}(x) = \frac{1}{n \cdot h} \sum_{i=1}^n K\left(\frac{x-x_i}{h}\right)$$




Jądrowy estymator gęstości prawdopodobieństwa (przykład)

Jądro Gaussowskie: $K(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}x^2}$, $n = 1000$, $h = 1$



Wpływ parametru wygładzania na kde




Wykres skrzynkowy

Wykres przedstawiający ważne parametry pozycyjne rozkładu:


- kwartyle
- średnia
- kształt rozkładu

Przydatny do porównywania różnych zbiorowości statystycznych
i znajdowania obserwacji odstających.

Wykres skrzynkowy





Wykres skrzynkowy




CI – przedział ufności


Wykres skrzynkowy (przykład)




Histogram 3D (przykład)



Wygładzony histogram 3D (przykład)



Wykres gęstościowy (przykład)



Zadanie 3

Scharakteryzuj i porównaj liczbę kalorii dostarczaną przez tłuszcze, węglowodany, białko i błonnik dla grupy wybranych produktów firmy Starbucks. Wykonaj wykresy skrzynkowe oraz estymację jądrową rozkładu prawdopodobieństwa.

Oblicz prawdopodobieństwo otrzymania potrawy zawierającej pomiędzy 200 a 300 kcal.

dane: `cw3.csv`

Dzięki za uwagę

infoShareAcademy.com