

Estymacja – przedziały ufności Junior Data Scientist

infoShare Academy



HELLO

Wojciech Artichowicz





01. Terminy podstawowe



Estymacja statystyczna

Wnioskowanie na podstawie próby statystycznej o rozkładzie prawdopodobieństwa zmiennej losowej.

Estymacja parametryczna – wnioskowanie o parametrach rozkładów prawdopodobieństwa

Estymacja nieparametryczna – wnioskowanie o populacji generalnej bez określania jej parametrów

Estymacja parametryczna

Wnioskowanie na podstawie próby statystycznej o parametrach rozkładu prawdopodobieństwa zmiennej losowej.

Rodzaje estymacji parametrycznej:

- estymacja punktowa
- estymacja przedziałowa
- testowanie hipotez parametrycznych

Estymator

Estymatorem parametru θ rozkładu prawdopodobieństwa zmiennej losowej jest pewna funkcja próby, na podstawie której można wnioskować o parametrze θ .

Estymator to sposób (wyrażenie) umożliwiające wnioskowanie o wartości parametru w populacji generalnej na podstawie próby.

Parametr, estymator, ocena parametru

$$f(x) = \frac{1}{\sigma \cdot \sqrt{2 \cdot \pi}} \cdot e^{-\frac{1}{2} \left(\frac{x - \mu}{\sigma} \right)^2}$$

μ , σ – parametry rozkładu

$$\left. \begin{aligned} \hat{\mu} &= \frac{1}{n} \sum_{i=1}^n x_i \\ \hat{\sigma} &= \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2} \end{aligned} \right\}$$

$\hat{\mu}$, $\hat{\sigma}$ – estymatory (wzór jak policzyć dany parametr)

$$\begin{aligned} m &= 3 \\ s &= 1 \end{aligned}$$

m, s – oceny parametrów

Podstawowe własności estymatorów

Obciążenie estymatora

Zgodność estymatora

Efektywność estymatora

Estymator nieobciążony

Estymator $\hat{\theta}_n(X_1, X_2, \dots, X_n; \theta)$ parametru θ jest nieobciążony jeśli

$$E[\hat{\theta}_n] = \theta$$

tn. jego wartość oczekiwana równa jest parametrowi.

Obciążeniem estymatora jest wartość

$$B_n = E[\hat{\theta}_n] - \theta$$

Estymator asymptotycznie nieobciążony:

$$\lim_{n \rightarrow \infty} B_n = 0$$

Zgodność estymatora

Estymator $\hat{\theta}_n(X_1, X_2, \dots, X_n; \theta)$ parametru θ jest zgodny, jeśli dla dowolnie małego ε zachodzi:

$$\lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| < \varepsilon) = 1$$

tn. przy wielkości próby dążącej do nieskończoności, wartość estymatora różni się od estymowanego parametru dowolnie mało.

Efektywność estymatora

Efektywnością estymatora nazywa się stosunek wariancji estymatora o najmniejszej wariancji do rozważanego estymatora.

$$e = \frac{V(\hat{\theta}_n^{(min)})}{V(\hat{\theta}_n^{(i)})}$$

Wybór estymatora

Pożądane własności estymatora:

- brak obciążenia lub asymptotyczna nieobciążoność
- najmniejsza wariancja
- zgodność

Metody znajdowania estymatorów

Metoda momentów

Metoda momentów liniowych

Metoda największej wiarygodności

Metoda najmniejszych kwadratów

inne...

Ćwiczenie 0

Dokonaj estymacji modelu statystycznego dla liczby punktów otrzymywanych przez studentów na egzaminie z matematyki (math score).

Jako rozkładu estymowanego użyj rozkładu normalnego i rozkładu normalnego (norm) ucinanego (truncnorm).

Plik z danymi: exams.csv

Dane pochodzą ze zbioru Students Performance in Exams (Kaggle)



02. **Ważne twierdzenia**

Dlaczego to wszystko działa?

Zbieżność ciągu dystrybuant

Ciąg dystrybuant $F_1(x), F_2(x), \dots$ jest zbieżny do nie malejącej funkcji $F(x)$, jeśli dla każdego punktu ciągłości x zachodzi

$$\lim_{n \rightarrow \infty} F_n(x) = F(x)$$

$F(x)$ nazywa się dystrybuantą rozkładu granicznego, natomiast $f(x) = F'(x)$ jest gęstością rozkładu granicznego.

Zbieżność ciągu zmiennych losowych

Ciąg zmiennych $X_1, X_2, \dots$ losowych jest stochastycznie zbieżny do zmiennej losowej X jeśli dla dowolnej małej nieujemnej liczby ε zachodzi

$$\lim_{n \rightarrow \infty} P(|X_n - X| > \varepsilon) = 0$$

Dla zmiennej losowej $Y_n = X_n - X$ ciąg $\{Y_n\}$ jest zbieżny stochastycznie do zera jeśli zachodzi

$$\lim_{n \rightarrow \infty} P(|Y_n| > \varepsilon) = 0$$

Twierdzenia graniczne

W twierdzeniach granicznych rozważa się graniczne własności ciągów zmiennych losowych.

Rodzaje twierdzeń granicznych:

- lokalne – dotyczą gęstości rozkładu prawdopodobieństwa (zmienne ciągłe) lub rozkładu prawdopodobieństwa (zmienne dyskretne)
- integralne – dotyczą dystrybuant
- prawa wielkich liczb – dotyczą stochastycznej zbieżności pewnych zmiennych losowych do zera

Centralne twierdzenia graniczne

Twierdzenia graniczne dotyczące sum niezależnych zmiennych losowych, których graniczną dystrybuantą jest rozkład normalny.

Przykłady twierdzeń granicznych

Całkowe	Lokalne	Prawa wielkich liczb
Lindberga-Levy'ego	Poissona	Chińczyna
Moivre'a-Laplace'a	Moivre'a-Laplace'a	Bernoullego
Lapunova		Borela-Cantellego

Centralne twierdzenie graniczne Lindberga-Levy'ego

Jeśli $\{X_n\}$ jest ciągiem niezależnych zmiennych losowych o identycznych rozkładach prawdopodobieństwa posiadających wartość oczekiwaną μ i skończoną wariancję $\sigma^2 \neq 0$. Wówczas dla ciągu dystrybuant $\{F_n(z)\}$ zmiennej losowej

$$Z_n = \frac{\sum_{i=1}^n X_i - n \cdot \mu}{\sigma \cdot \sqrt{n}}$$

zachodzi

$$\lim_{n \rightarrow \infty} F_n(z) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^z e^{-\frac{1}{2}u^2} du$$

Centralne twierdzenie graniczne Lindberga-Levy'ego

Twierdzenie to oznacza, że dowolna zmienna losowa Y_n będąca sumą identycznych i niezależnych zmiennych losowych X_n

$$Y_n = \sum_{i=1}^n X_i$$

ma rozkład normalny o wartości oczekiwanej $E[Y_n] = n \cdot \mu$ i odchyleniu standardowym $S[Y_n] = \sigma\sqrt{n}$

Centralne twierdzenie graniczne Lindberga-Levy'ego

Jeśli jakaś statystyka opiera się na obliczeniu sumy zmiennych losowych (np. średnia) to można na jej temat wnioskować, nie znając rozkładu, z którego pochodzi próba:

Np. średnia z próby dużej podlega rozkładowi normalnemu.

Z własności tej korzysta się np. przy obliczaniu przedziałów ufności dla średniej, gdy próba jest duża ($n > 30$), a rozkład, z którego pochodzi próba jest nieznany




03. Przedziały ufności

Konstrukcja przedziałów ufności

Estymacja punktowa

Polega na znalezieniu takiej wartości parametru rozkładu prawdopodobieństwa, która będzie możliwie najlepsza.

Parametryczna estymacja rozkładu



Estymacja przedziałowa

Estymacja przedziałowa polega na zbudowaniu takiego przedziału, który pokrywa (z prawdopodobieństwem bliskim jedności) prawdziwą wartość szukanego parametru w populacji generalnej.


Przedziały ufności zwykle konstruuje się dla

- wartości średniej
- odchylenia standardowego
- proporcji

Przedział ufności



Przedziałem ufności parametru θ rozkładu prawdopodobieństwa w populacji generalnej nazywa się przedział $[T_n^{(1)}, T_n^{(2)}]$, którego granice zależą od próby i nie zależą od poszukiwanego parametru. Przedział taki pokrywa szukaną wartość parametru z prawdopodobieństwem $1 - \alpha$.

$$P\left(T_n^{(1)} \leq \theta \leq T_n^{(2)}\right) = 1 - \alpha$$




Poziom ufności

Prawdopodobieństwo $1 - \alpha$, że otrzymany przedział ufności pokryje prawdziwą wartość estymowanego parametru w populacji generalnej.



Wyznaczanie przedziału ufności parametru



Oznaczenia

μ – wartość oczekiwana w populacji generalnej,

σ – odchylenie standardowe w populacji generalnej

$X \sim N(\mu, \sigma)$ - zmienna losowa X ma rozkład normalny ze średnią μ i odchyleniem standardowym σ

u_p - kwantyl rzędu p standaryzowanego rozkładu normalnego $N(0,1)$

$X \sim T(df)$ - zmienna losowa X ma rozkład T -Studenta z liczbą stopni swobody równą df

$t_{df,p}$ - kwantyl rzędu p rozkładu T -Studenta z liczbą stopni swobody równą df

$X \sim \chi^2(df)$ - zmienna losowa X ma rozkład χ^2 z liczbą stopni swobody równą df

$\chi^2_{df,p}$ - kwantyl rzędu p rozkładu χ^2 z liczbą stopni swobody równą df

$\bar{X}$ – zmienna losowa będąca średnią z próby

CI_θ - przedział ufności dla parametru θ


Oznaczenia

$(1 - \alpha)$ – poziom ufności

n – liczebność próby

$\bar{x}$ – wartość oczekiwana w próbie,

s – odchylenie standardowe w próbie



Wyprowadzenie przedziału ufności dla średniej

Założenia:

$$X \sim N(\mu, \sigma)$$

σ jest znane

Rozkład statystyki:

$$\bar{X} \sim N\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$$


Statystyka standaryzowana:

$$\frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \sim N(0,1)$$

Wyprowadzenie przedziału ufności dla średniej

Prawdopodobieństwo, że statystyka przyjmie wartość z pewnego przedziału ma być równe $1 - \alpha$

$$P\left(u_{\frac{\alpha}{2}} \leq \frac{\bar{X} - \mu}{\sigma} \sqrt{n} \leq u_{1-\frac{\alpha}{2}}\right) = 1 - \alpha$$



Ze względu na symetrię $N(0,1)$ kwantyle $-u_{\frac{\alpha}{2}} = u_{1-\frac{\alpha}{2}}$, wzór

$$P\left(\bar{X} - \frac{\sigma}{\sqrt{n}} u_{1-\frac{\alpha}{2}} \leq \mu \leq \bar{X} + \frac{\sigma}{\sqrt{n}} u_{1-\frac{\alpha}{2}}\right) = 1 - \alpha$$

Wyprowadzenie przedziału ufności dla odchylenia standardowego

Założenia:


$$X \sim N(\mu, \sigma)$$

Rozkład statystyki:

$$\frac{n \cdot s^2}{\sigma^2} \sim \chi_{n-1}^2$$

Rozkład jest niesymetryczny, więc wymagane jest dodatkowe założenie:

$$P\left\{\chi_{n-1}^2 < \chi_{n-1}^{2(1)}\right\} = P\left\{\chi_{n-1}^{2(2)} < \chi_{n-1}^2\right\} = \frac{\alpha}{2}$$




$$\chi_{n-1}^{2(1)} = \chi_{n-1, \frac{\alpha}{2}}^2; \quad \chi_{n-1}^{2(2)} = \chi_{n-1, 1-\frac{\alpha}{2}}^2$$

Wyprowadzenie przedziału ufności dla odchylenia standardowego

$$P\left(\chi_{n-1, \frac{\alpha}{2}}^2 \leq \frac{n \cdot s^2}{\sigma^2} \leq \chi_{n-1, 1-\frac{\alpha}{2}}^2\right) = 1 - \alpha$$

$$P\left(s \sqrt{\frac{n}{\chi_{n-1, 1-\frac{\alpha}{2}}^2}} \leq \sigma \leq s \sqrt{\frac{n}{\chi_{n-1, \frac{\alpha}{2}}^2}}\right) = 1 - \alpha$$



Przedziały ufności dla średniej

Model 1: Założenia: $X \sim N(\mu, \sigma)$; σ ; rozmiar próby jest bez znaczenia

$$CI_{\mu} = \left[\bar{x} - \frac{\sigma}{\sqrt{n}} u_{1-\frac{\alpha}{2}} ; \bar{x} + \frac{\sigma}{\sqrt{n}} u_{1-\frac{\alpha}{2}} \right]$$

Model 2: Założenia: $X \sim N(\mu, \sigma)$; próba jest mała ($n < 30$)

$$CI_{\mu} = \left[\bar{x} - \frac{s}{\sqrt{n}} t_{n-1, 1-\frac{\alpha}{2}} ; \bar{x} + \frac{s}{\sqrt{n}} t_{n-1, 1-\frac{\alpha}{2}} \right]$$

Model 3: Założenia: $X \sim \text{dowolny}$; próba jest duża ($n > 30$)

$$CI_{\mu} = \left[\bar{x} - \frac{s}{\sqrt{n}} u_{1-\frac{\alpha}{2}} ; \bar{x} + \frac{s}{\sqrt{n}} u_{1-\frac{\alpha}{2}} \right]$$

gdzie: s – odchylenie standardowe próby, n – wielkość próby

$u \sim N(0,1)$, $t \sim T(n-1)$

Przedziały ufności dla średniej (przykład 1)



"5d_1115_1612-75" by Indiana Stan
licensed under CC BY-NC 2.0

Badano średnią kwotę na jaką klienci pewnego marketu dokonują zakupów w niedzielę handlową.

Zanotowano kwotę zakupów $n = 130$ klientów. Otrzymano średnią $\bar{x} = 124$ PLN przy odchyleniu standardowym $s = 50$ PLN. Zbuduj przedział ufności dla średniej ceny zakupów przy poziomie ufności $1 - \alpha = 0,95$.

Wybór modelu: próba duża, nieznane $\sigma \rightarrow$ Model 3

$$CI_{\mu} = \left[\bar{x} - \frac{s}{\sqrt{n}} u_{1-\frac{\alpha}{2}} ; \bar{x} + \frac{s}{\sqrt{n}} u_{1-\frac{\alpha}{2}} \right]$$

$$u_{1-\frac{\alpha}{2}} = 1,95996$$

$$CI_{\mu} = [115,405; 132,595]$$

Ćwiczenie 1

Dany jest zbiór informacji o aplikacjach Google Play.

Przyjmując poziom ufności $1 - \alpha = 0,99$, określ przedział ufności dla średniej oceny aplikacji w kategorii Tools.

Dane: `googleplaystore.csv`.

Ćwiczenie 1 - rozwiązanie

1. Sprawdzenie założeń / wybór modelu:

próba duża, nieznane $\sigma \rightarrow$ Model 3

$$CI_{\mu} = \left[\bar{x} - \frac{s}{\sqrt{n}} u_{1-\frac{\alpha}{2}} ; \bar{x} + \frac{s}{\sqrt{n}} u_{1-\frac{\alpha}{2}} \right]$$

2. Określenie wymaganych wartości:

$$\bar{x} = 4,05; s = 0,62; n = 734; u_{1-\frac{\alpha}{2}} = 2,57583$$

3. Wykonanie obliczeń

$$CI_{\mu} = [3,99; 4,11]$$

Przedziały ufności dla różnicy między średnimi

Model 1: Założenia: $X \sim N(\mu_X, \sigma_X)$, $Y \sim N(\mu_Y, \sigma_Y)$; σ_X i σ_Y są znane

$$CI_{\mu_X - \mu_Y} = \left[(\bar{x} - \bar{y}) - u_{1-\frac{\alpha}{2}} \sqrt{\frac{\sigma_X^2}{n_x} + \frac{\sigma_Y^2}{n_y}} ; (\bar{x} - \bar{y}) + u_{1-\frac{\alpha}{2}} \sqrt{\frac{\sigma_X^2}{n_x} + \frac{\sigma_Y^2}{n_y}} \right]$$

Model 2: Założenia: $X \sim N(\mu_X, \sigma_X)$, $Y \sim N(\mu_Y, \sigma_Y)$; $\sigma_X = \sigma_Y = \sigma$ jest nieznane

$$CI_{\mu_X - \mu_Y} = \left[(\bar{x} - \bar{y}) - t_{n_x+n_y-2, 1-\frac{\alpha}{2}} \sqrt{\frac{s^2}{n_x} + \frac{s^2}{n_y}} ; (\bar{x} - \bar{y}) + t_{n_x+n_y-2, 1-\frac{\alpha}{2}} \sqrt{\frac{s^2}{n_x} + \frac{s^2}{n_y}} \right]$$

Przedział ufności dla odchylenia standardowego

Model: Założenia: $X \sim N(\mu, \sigma)$

$$CI_{\sigma} = \left[s \sqrt{\frac{n}{\chi^2_{n-1, 1-\frac{\alpha}{2}}}}; s \sqrt{\frac{n}{\chi^2_{n-1, \frac{\alpha}{2}}}} \right]$$

Przedział ufności dla stosunku dwóch wariancji

Model: Założenia: $X \sim N(\mu_X, \sigma_X)$, $Y \sim N(\mu_Y, \sigma_Y)$

$$CI_{\frac{\sigma_X^2}{\sigma_Y^2}} = \left[\frac{S_X^2}{S_Y^2} f_{n_x-1, n_y-1, \frac{\alpha}{2}}; \frac{S_X^2}{S_Y^2} f_{n_x-1, n_y-1, 1-\frac{\alpha}{2}} \right]$$

Przedział ufności dla proporcji

Model: Próba duża ($n > 25$)

$$CI_p = \left[\hat{p} - u_{1-\frac{\alpha}{2}} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}; \hat{p} + u_{1-\frac{\alpha}{2}} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \right]$$

$\hat{p}$ - wskaźnik proporcji w próbie

Przedziały ufności dla proporcji (przykład

2)



"buying" is licensed under [CC0 1.0](#)

W sklepie internetowym zbadano liczbę transakcji z jednego dnia. Dokonano $n = 5000$ zakupów, z czego 200 było wynikiem przekierowania (kliknięcia w reklamę na stronie internetowej). Na poziomie ufności $1 - \alpha = 0,99$ określ przedział ufności dla proporcji.


$$CI_p = \left[\hat{p} - u_{1-\frac{\alpha}{2}} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}; \hat{p} + u_{1-\frac{\alpha}{2}} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \right]$$

$$\hat{p} = \frac{200}{5000} = 0,04; u_{1-\frac{\alpha}{2}} = 2,57583$$

$$CI_p = [0,03286; 0,04713]$$

Przedział ufności - komentarz

Z populacji generalnej $X \sim N(0,1)$ wylosowano 100 prób ($n = 25$) i określono dla każdej z nich przedział ufności $1 - \alpha = 0,95$.





Metoda bootstrap

Mając daną n -elementową próbę losową, zwaną tu próbą pierwotną, $\{x_1, x_2, \dots, x_n\}$, traktuje się ją jako populację.

Z próby tej losuje się ze zwracaniem k n -elementowych prób (tzw. prób bootstrapowych).

Wartość k to minimum 1000.

Metoda bootstrap (przykład)

Rzucono kostką 5 razy, otrzymując następującą realizację:

$$\{x_1, x_2, x_3, x_4, x_5\} = \{6, 3, 3, 2, 5\}$$

Próby bootstrapowe:

$$\{x_1, x_2, x_3, x_4, x_5\}_1 = \{2, 6, 2, 3, 2\}$$

$$\{x_1, x_2, x_3, x_4, x_5\}_2 = \{2, 6, 3, 5, 3\}$$

$$\{x_1, x_2, x_3, x_4, x_5\}_3 = \{6, 3, 5, 2, 3\}$$

...

Rozkład typu bootstrap

Jest to rozkład graniczny statystyki $Z_n = g(X_1, X_2, \dots, X_n)$ znaleziony metodą powtarzanego losowania. Oznacza się go jako $F_{Z_n}^*$.


Rozkład typu bootstrap(przykład)

Otrzymano następującą próbę pochodzącą z rozkładu eksponentialnego:


$x = \{3,5; 3,72; 3,42; 0,46; 0,45; 2,21; 3,54; 4,02; 2,09; 0,05; 2,12; 1,88; 0,68; 0,32; 0,18; 0,5; 1,34; 0,22; 0,31; 3,7\}$

Rozkład typu bootstrap

średniej



wariancji



Przedziały ufności typu bootstrap

Model 1: Założenia: brak

$$P_{\hat{\theta}} \left(\hat{\theta}^* - q_{1-\frac{\alpha}{2}}^* \leq \hat{\theta} \leq \hat{\theta}^* - q_{\frac{\alpha}{2}}^* \right) = 1 - \alpha$$

Model 2: Założenia: statystyka $\hat{\theta}^*$ ma w przybliżeniu rozkład normalny $N(\mu_{\hat{\theta}}, \sigma_{\hat{\theta}})$

$$P_{\hat{\theta}} \left(\hat{\theta}^* - u_{1-\frac{\alpha}{2}} SE_{\hat{\theta}^*} \leq \hat{\theta} \leq u_{1-\frac{\alpha}{2}} SE_{\hat{\theta}^*} \right) = 1 - \alpha$$

gdzie: $\hat{\theta}$ - rozważany estymator, $\hat{\theta}^*$ - bootstrapowa ocena estymatora,

$q_{\frac{\alpha}{2}}^*, q_{1-\frac{\alpha}{2}}^*$ - kwantyle rozkładu typu bootstrap dla statystyki $(\hat{\theta}^* - \hat{\theta})$

$SE_{\hat{\theta}^*} = \sqrt{\frac{1}{k-1} \sum_{i=1}^k (\hat{\theta}_i^* - \bar{\theta}^*)^2}$ - błąd standardowy estymatora typu bootstrap

k - liczba prób typu bootstrap

Przedziały ufności typu bootstrap (przykład)

Przedziały ufności określone metodą bootstrap dla wartości średniej małej próbki pochodzącej z rozkładu normalnego ($X \sim N(\mu, \sigma)$). Otrzymane wyniki porównano z modelem opartym o rozkład T-Studenta.

x_i	8,00	10,62	3,00	6,31	3,13	2,16	4,60	1,96	3,66	6,31
	6,18	6,36	5,81	4,92	9,74	4,68	-1,71	2,21	8,05	3,22

$$k = 2000$$

$$\bar{\theta}^* = 5.323$$


$$SE_{\hat{\theta}^*} = 0.4556$$

$$CI_{\mu} = [3,700; 6,265] \text{ (bootstrap Model 1)}$$

$$CI_{\mu} = [3,715; 6,206] \text{ (bootstrap Model 2)}$$

$$CI_{\mu} = [3,592; 6.330] \text{ (rozkład T-Studenta)}$$

Przedziały ufności typu bootstrap (przykład)



Otrzymany rozkład typu bootstrap



Zadanie 2

Dany jest zbiór informacji o aplikacjach z Google Play.

Przyjmując poziom ufności $1 - \alpha = 0,99$, określ przedział ufności dla proporcji liczby aplikacji, które zostały zainstalowane 1 000 000 000+ razy.

Dane: `googleplaystore.csv`.

Zadanie 2

1. Przygotowanie danych
2. Sprawdzenie założeń i wybór modelu:
Próba duża

$$CI_p = \left[\hat{p} - u_{1-\frac{\alpha}{2}} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}; \hat{p} + u_{1-\frac{\alpha}{2}} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \right]$$

3. Określenie wymaganych wartości

$$n = 10841; \hat{p} = \frac{58}{10481} = 0,00535; u_{1-\frac{\alpha}{2}} = 2,57583$$

4. Wykonanie obliczeń

$$CI_p = [0,00354539; 0,00715473]$$

Zadanie 3

Określ przedział ufności dla stopnia konwersji (conversion rate) użytkowników aktualnej strony internetowej (old_website). Przyjmij poziom ufności $1 - \alpha = 0,999$.

(Zaniedbaj kwestię poprawności danych: np. duplikaty użytkowników itd.)
Kolumny: *landing_page:old_page; conversion:1*.

Dane: `ab_data.csv`.

Zadanie 3 - rozwiązanie

1. Przygotowanie danych
2. Sprawdzenie założeń i wybór modelu:

Próba duża

$$CI_p = \left[\hat{p} - u_{1-\frac{\alpha}{2}} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}; \hat{p} + u_{1-\frac{\alpha}{2}} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \right]$$

3. Określenie wymaganych wartości

$$n = 147239; k = 17739; \hat{p} = \frac{k}{n} = 0,120; u_{1-\frac{\alpha}{2}} = 3,29053$$

4. Wykonanie obliczeń

$$CI_p = [0,118; 0,123]$$

Dzięki za uwagę

infoShareAcademy.com