

Estymacja – testy Junior Data Scientist

infoShare Academy



HELLO

Wojciech Artichowicz





01. Terminy podstawowe

Hipoteza statystyczna

Przypuszczenie dotyczące rozkładu (lub jego parametrów) zmiennej losowej, o którego prawdziwości można wnioskować na podstawie próby będącej realizacją tej zmiennej losowej.

Hipoteza zerowa i alternatywna

Hipotezę, którą poddaje się sprawdzianowi określa się mianem hipotezy zerowej i oznacza symbolem H_0 .

Hipotezę, którą przyjmuje się w przypadku odrzucenia hipotezy zerowej, nazywa się hipotezą alternatywną i oznacza symbolem H_1 .

Błąd pierwszego i drugiego rodzaju

Błąd pierwszego rodzaju określa odrzucenie hipotezy zerowej w przypadku, gdy jest ona prawdziwa. (Związany z poziomem istotności.)

Błąd drugiego rodzaju określa nie odrzucenie hipotezy zerowej w przypadku, gdy jest ona fałszywa. (Związany z mocą testu.)

Poziom istotności

Poziomem istotności α nazywa się (z góry założone) prawdopodobieństwo popełnienia błędu pierwszego rodzaju (odrzućenia prawdziwej hipotezy zerowej)

Poziom istotności

Poziomem istotności α nazywa się (z góry założone) prawdopodobieństwo popełnienia błędu pierwszego rodzaju (odrzućenia prawdziwej hipotezy zerowej)


Poziom istotności zwykle przyjmuje się równy 0,05, 0,01, 0,001. Jeśli p -wartość otrzymana w wyniku testu jest mniejsza niż przyjęty poziom istotności, hipotezę zerową odrzuca się. Kwestia przyjęcia poziomu istotności zależy od wagi rozwiązywanego zadania. Np. w medycynie gdzie zła decyzja może być zagrożeniem dla życia pacjentów powinny to być bardzo małe wartości np. $\alpha = 10^{-4}$ i mniejsze.

Interpretacja graficzna: Poziom istotności to część obszaru pola pod wykresem rozkładu prawdopodobieństwa statystyki testowej w jej obszarze krytycznym.


Obszar krytyczny

Jest to zbiór wartości statystyki testowej, przy osiągnięciu których odrzuca się hipotezę zerową.


Dwustronny



Lewostronny



Prawostronny



Moc testu

Moc testu $1 - \beta$ określa się prawdopodobieństwo odrzucenia fałszywej hipotezy zerowej i przyjęcia hipotezy alternatywnej
(prawdopodobieństwo nie popełnienia błędu drugiego rodzaju)

Wartość β jest prawdopodobieństwem popełnienia błędu drugiego rodzaju.



p -wartość

Najmniejszy poziom istotności, przy którym otrzymana wartość statystyki testowej prowadzi do odrzucenia hipotezy zerowej.

p -wartość

Najmniejszy poziom istotności, przy którym otrzymana wartość statystyki testowej prowadzi do odrzucenia hipotezy zerowej.

Im mniejsza jest p -wartość tym bardziej uzasadnione jest odrzucenie hipotezy zerowej.

W pewnym sensie p -wartość można utożsamiać z prawdopodobieństwem zdarzenia polegającego na tym, że zaobserwowane w próbie wartości są wynikiem przypadku. Jeśli p -wartość jest bardzo mała to znaczy, że obserwacje w próbie (czy między próbami) są bardzo mało prawdopodobne, jeśli założyć że nie istnieje żaden czynnik powodujący te różnice.

p -wartość

Hipoteza zerowa:

$$H_0: \theta = \theta_0$$

obszar krytyczny	p -wartość	hipoteza alternatywna
lewostronny	$P_{H_0}(X \leq x)$	$H_1: \theta < \theta_0$
obustronny (rozkłady symetryczne)	$2P_{H_0}(X \geq x)$	$H_1: \theta \neq \theta_0$
prawostronny	$P_{H_0}(X \geq x)$	$H_1: \theta > \theta_0$

θ_0 - założona wartość parametru, X – zmienna losowa statystyki testowej,
 x – wartość statystyki testowej



02. Testy parametryczne

Testy dla średniej, proporcji, odchylenia standardowego

Testy dla średniej

Hipoteza zerowa:

$$H_0: \mu = \mu_0$$

Hipoteza alternatywna:

$$H_1: \mu < \mu_0$$

$$H_1: \mu \neq \mu_0$$


$$H_1: \mu > \mu_0$$

Obszar krytyczny:

lewostronny

dwustronny

prawostronny



Testy dla średniej

Model 1: Założenia: $X \sim N(\mu, \sigma)$; σ ; rozmiar próby jest bez znaczenia

Statystyka testowa $u = \frac{\bar{x} - \mu_0}{\sigma} \sqrt{n}$ ma rozkład $N(0,1)$

Model 2: Założenia: $X \sim N(\mu, \sigma)$; próba jest mała ($n < 30$)

Statystyka testowa $t = \frac{\bar{x} - \mu_0}{s} \sqrt{n}$ ma rozkład $T(n - 1)$

Model 3: Założenia: $X \sim \text{dowolny}$; próba jest duża ($n > 30$)

Statystyka testowa $u = \frac{\bar{x} - \mu_0}{s} \sqrt{n}$ ma rozkład $N(0,1)$

gdzie: s – odchylenie standardowe próby, n – wielkość próby

Testy dla dwóch średnich

Hipoteza zerowa:

$$H_0: \mu_X = \mu_Y$$

Hipoteza alternatywna:

$$H_1: \mu_X < \mu_Y$$

$$H_1: \mu_X \neq \mu_Y$$


$$H_1: \mu_X > \mu_Y$$

Obszar krytyczny:

lewostronny

dwustronny

prawostronny



Testy dla dwóch średnich

Model 1: Założenia: $X \sim N(\mu_X, \sigma_X)$, $Y \sim N(\mu_Y, \sigma_Y)$; σ_X i σ_Y są znane

Statystyka testowa $u = \frac{\bar{x} - \bar{y}}{\sqrt{\frac{\sigma_X^2}{n_x} + \frac{\sigma_Y^2}{n_y}}}$ ma rozkład $N(0,1)$

Model 2: Założenia: $X \sim N(\mu_X, \sigma_X)$, $Y \sim N(\mu_Y, \sigma_Y)$; $\sigma_X = \sigma_Y = \sigma$ jest nieznane

Statystyka testowa $t = \frac{\bar{x} - \bar{y}}{\sqrt{\frac{n_x s_X^2 + n_y s_Y^2}{n_x + n_y - 2} \cdot \frac{n_x + n_y}{n_x n_y}}}$ ma rozkład $T(n_x + n_y - 2)$

Testy dla dwóch średnich

Model 3: Założenia: $X \sim N(\mu_X, \sigma_X)$, $Y \sim N(\mu_Y, \sigma_Y)$; σ_X i σ_Y są nieznane, próby małe

Statystyka testowa

$$t = \frac{\bar{x} - \bar{y}}{\sqrt{\frac{s_X^2}{n_x} + \frac{s_Y^2}{n_y}}}$$

ma rozkład $t \sim T(df)$ gdzie

$$df = \frac{\left(\frac{s_X^2}{n_x} + \frac{s_Y^2}{n_y}\right)^2}{\frac{1}{n_x - 1} \left(\frac{s_X^2}{n_x}\right)^2 + \frac{1}{n_y - 1} \left(\frac{s_Y^2}{n_y}\right)^2}$$

Testy dla dwóch średnich

Model 4: Założenia: $X \sim N(\mu_X, \sigma_X)$, $Y \sim N(\mu_Y, \sigma_Y)$; σ_X i σ_Y są nieznane,
próba duża ($n_x, n_y \geq 100$)

Statystyka testowa

$$u = \frac{\bar{x} - \bar{y}}{\sqrt{\frac{s_X^2}{n_x} + \frac{s_Y^2}{n_y}}}$$

ma rozkład $N(0,1)$

Test ten został wyprowadzony przy założeniu, że X i Y mają rozkłady normalne, jednak w przypadku dużych prób, (na mocy tw. granicznych) możliwe jest otrzymanie dobrych wyników nawet, gdy rozkłady te nie są normalne.

Testy dla dwóch średnich

Model 5: Założenia: **PARY WIĄZANE**, $X \sim N(\mu_X, \sigma_X)$, $Y \sim N(\mu_Y, \sigma_Y)$; σ_X i σ_Y są nieznane

Statystyka testowa $t = \frac{\bar{x} - \bar{y}}{s_{x-y}} \sqrt{n}$ ma rozkład $T(n - 1)$, gdzie

$$s_{x-y} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n ((x_i - y_i) - (\bar{x} - \bar{y}))^2}$$

Termin **pary wiązane** oznacza logicznie powiązane jednostki np. pacjent przed i po podaniu leku, mąż i żona, ten sam sklep przed i po kampanii marketingowej itp.

Ćwiczenie 4

Badano ocenę poprawy jakości życia pacjentów z depresją po wprowadzeniu dwóch różnych leków. Zmienna **rating** określa samopoczucie pacjenta po pewnym czasie stosowania leków. Jedna grupa pacjentów przyjmowała *Zoloft* druga *Desvenlafaxine*. Zweryfikuj hipotezę, że *Zoloft* jest lekiem mniej skutecznym.

Uwaga: Dane na temat samopoczucia nie dotyczą tych samych pacjentów, a dwóch grup różnych pacjentów.

Dane: **depression.csv**.

<https://www.kaggle.com/iancornish/drug-data>

Zadanie 4 - komentarz

Zadanie polega na sprawdzeniu, czy *Zoloft* jest mniej skuteczny niż *Desvenlafaxine* w kwestii poprawy samopoczucia pacjentów z depresją. Zagadnienie to można przedstawić nieco inaczej: który lek statystycznie otrzymuje lepsze oceny od pacjentów (bardziej poprawia ich jakość życia).

W związku z tym jako hipotezę zerową należy przyjąć $H_0: \mu_X = \mu_Y$. W przypadku, gdy hipoteza ta zostanie odrzucona, oznaczać to będzie, że oceny pacjentów dla tych dwóch leków istotnie się różnią.

Jako, że celem badania jest sprawdzenie, czy *Zoloft* jest mniej skuteczny niż *Desvenlafaxine* należy wybrać jednostronny obszar krytyczny. Przyjmując oznaczenia X – *Zoloft*, Y – *Desvenlafaxine* należy przyjąć lewostronny obszar krytyczny (czyli obliczać p -wartość od lewej strony jako $P(u)$).

Gdyby przyjąć oznaczenia odwrotnie, wówczas aby wnioskować o tym samym należałoby przyjąć prawostronny obszar krytyczny (czyli obliczać p -wartość od lewej strony jako $1 - P(u)$).

Zadanie 4 - komentarz

Należy zauważyć, że w przypadku tak sformułowanego zagadnienia i przyjęcia lewostronnego obszaru krytycznego sytuacja, w której statystyka testowa wykaże, że *Zoloft* jest istotnie bardziej skuteczny niż *Desvenlafaxine* nie zostanie spostrzeżona, ponieważ przedmiotem testu jest sprawdzenie czy *Zoloft* jest mniej skuteczny.

Gdyby badanie miało na celu stwierdzenie, czy istnieje statystycznie istotna różnica między lekami, wówczas należałoby przyjąć hipotezę alternatywną postaci $H_1: \mu_X \neq \mu_Y$ co implikowałoby obustronny obszar krytyczny. W takiej sytuacji silne wychylenie statystyki testowej w kierunku wartości dodatnich czy ujemnych spowodowałoby odrzucenie hipotezy zerowej.

Zadanie 4 - rozwiązanie

1. Przygotowanie danych
2. Sprawdzenie założeń:
rozkłady nie są normalne
próby są duże
3. Wybór modelu: Model 4

$$u = \frac{\bar{x} - \bar{y}}{\sqrt{\frac{s_x^2}{n_x} + \frac{s_y^2}{n_y}}}$$


4. Określenie wymaganych wartości:

X – Zoloft, Y - Desvenlafaxine

$$\bar{x} = 6,914, \quad \bar{y} = 6,969$$

$$s_x = 3,095, \quad \bar{s}_y = 3,125$$

$$n_x = 105, \quad n_y = 159$$



Zadanie 4 - rozwiązanie

5. Sformułowanie hipotezy zerowej

$$H_0: \mu_X = \mu_Y$$

6. Sformułowanie hipotezy alternatywnej


$$H_1: \mu_X < \mu_Y$$

7. Przeprowadzenie obliczeń:

$$u = -0,1389$$

$$p_{value} = 0,445$$

8. Podjęcie decyzji: brak wskazań do odrzucenia hipotezy zerowej. Na podstawie danych nie można stwierdzić, że *Zoloft* jest lekiem mniej skutecznym niż *Desvenlafaxine*



Testy dla wariancji

Hipoteza zerowa: $H_0: \sigma^2 = \sigma_0^2$

Hipoteza alternatywna:

$$H_1: \sigma^2 < \sigma_0^2$$

$$H_1: \sigma^2 \neq \sigma_0^2$$

$$H_1: \sigma^2 > \sigma_0^2$$

Obszar krytyczny:

lewostronny

dwustronny

prawostronny

Testy dla wariancji

Model 1: Założenia: $X \sim N(\mu, \sigma)$; rozmiar próby jest bez znaczenia

Statystyka testowa $\chi^2 = \frac{ns^2}{\sigma_0^2}$ ma rozkład $\chi^2(n-1)$

Model 2: Założenia: $X \sim \text{dowolny}$; próba jest duża ($n > 100$)

Statystyka testowa $u = \frac{s^2 - \sigma_0^2}{\sigma_0^2}$ ma rozkład $N(0,1)$

Test dla dwóch wariancji

Hipoteza zerowa: $H_0: \sigma_X^2 = \sigma_Y^2$

Hipoteza alternatywna:

$$H_1: \sigma_X^2 < \sigma_Y^2$$

$$H_1: \sigma_X^2 \neq \sigma_Y^2$$

$$H_1: \sigma_X^2 > \sigma_Y^2$$

Obszar krytyczny:

lewostronny

dwustronny

prawostronny

Model: Założenia: $X \sim N(\mu_X, \sigma_X)$; $Y \sim N(\mu_Y, \sigma_Y)$

Statystyka testowa $F = \frac{s_X^2}{s_Y^2}$ ma rozkład $F(n_x - 1, n_y - 1)$

Test Bartletta dla wielu wariancji

Hipoteza zerowa: $H_0: \sigma_1^2 = \sigma_2^2 = \dots = \sigma_k^2 \quad (k \geq 3)$

Hipoteza alternatywna:

H_1 : *nie wszystkie wariancje są sobie równe*

Obszar krytyczny:

prawostronny

Model: Założenia: $X_i \sim N(\mu_i, \sigma_i)$;

$$\text{Statystyka } \chi^2 = \frac{(n-r) \ln \left(\frac{\sum_{j=1}^r \sum_{i=1}^{n_j} (x_{ij} - \bar{x}_j)^2}{n-r} \right) - \sum_{j=1}^r (n_j - 1) \ln(s_j^2)}{1 + \frac{1}{3(r-1)} \left[\sum_{j=1}^r \left(\frac{1}{n_j - 1} \right) - \frac{1}{n-r} \right]} \quad \text{ma rozkład } \chi^2(r-1)$$

r – liczba grup, n – liczba obserwacji, n_j – liczba obserwacji w grupie j .

Test dla wskaźnika struktury

Hipoteza zerowa: $H_0: p = p_0$

Hipoteza alternatywna:

$$H_1: p < p_0$$

$$H_1: p \neq p_0$$

$$H_1: p > p_0$$

Obszar krytyczny:

lewostronny

dwustronny

prawostronny

Model: Próba jest duża ($n \geq 100$)

Statystyka testowa $u = \frac{k - n p_0}{\sqrt{n p_0 (1 - p_0)}}$ ma rozkład $N(0,1)$

Test dla wskaźnika struktury – modyfikacja dla małej próby

Gdy próba jest mała, to stosuje się przekształcenie, w którym statystyką testową jest

$$u = 2 \left(\arcsin \sqrt{\frac{k}{n}} - \arcsin \sqrt{p_0} \right) \sqrt{n}$$

która ma rozkład $N(0,1)$

Test dla dwóch wskaźników struktury

Hipoteza zerowa:

$$H_0: p_X = p_Y$$

Hipoteza alternatywna:

$$H_1: p_X < p_Y$$

$$H_1: p_X \neq p_Y$$

$$H_1: p_X > p_Y$$

Obszar krytyczny:

lewostronny

obustronny

prawostronny

Model: Próba jest duża ($n_x, n_y \geq 100$)

Statystyka testowa

$$u = \frac{\frac{k_x}{n_x} - \frac{k_y}{n_y}}{\sqrt{\frac{k_x + k_y}{n_x \cdot n_y} \left(1 - \frac{k_x + k_y}{n_x + n_y}\right)}}$$

ma rozkład $N(0,1)$

Test dla dwóch wskaźników struktury – modyfikacja dla małej próby

Gdy próba jest mała, to stosuje się przekształcenie, w którym statystyką testową jest

$$u = 2 \left(\arcsin \sqrt{\frac{k_x}{n_x}} - \arcsin \sqrt{\frac{k_y}{n_y}} \right) \sqrt{\frac{n_x n_y}{n_x + n_y}}$$

która ma rozkład $N(0,1)$

Ćwiczenie 5

Przeprowadzono testy A/B pewnej strony internetowej. Sprawdź hipotezę, że zmiany wprowadzone na stronie pozytywnie wpływają na konwersję (czyli ją zwiększają).

Dane: `ab_data.csv`.

<https://www.kaggle.com/zhangluyuan/ab-testing>

Ćwiczenie 5- komentarz

Celem przeprowadzenia testu jest stwierdzenie, czy stopień konwersji wzrósł (tzn. czy proporcja się zwiększyła). W testach statystycznych badającemu „zależy” na sprawdzeniu i ewentualnym odrzuceniu hipotezy zerowej. Zatem postawiona hipoteza zerowa, mówi o braku wpływu zmian na stronie internetowej na wynik konwersji, tj: zakłada się, że proporcje przed i po wprowadzeniu zmian są sobie równe. Postawiona hipoteza zerowa to: $H_0: p_X = p_Y$. Jeśli hipoteza ta zostanie odrzucona to znaczy, że nastąpiła statystycznie istotna zmiana w proporcji.

Pozostaje jeszcze kwestia hipotezy alternatywnej. Indeksom X oznaczmy stronę bez zmian, a Y stronę ze zmianami. Interesuje nas sytuacja zwiększenia konwersji, zatem hipotezą alternatywną będzie: $H_1: p_X < p_Y$ (proporcja przed wprowadzeniem zmian jest mniejsza niż po wprowadzeniu zmian). Jeśli otrzymana p -wartość jest mała to hipotezę należy odrzucić, jeśli nie to nie ma podstaw do jej odrzucenia.

Należy zauważyć, że w już uściślonym zagadnieniu (po określeniu lewostronnego obszaru krytycznego) hipoteza zerowa nie zostanie odrzucona w przypadku, gdy stopień konwersji zmniejszył się po wprowadzeniu zmian.

Ćwiczenie 5- rozwiązanie

1. Przygotowanie danych
2. Sprawdzenie założeń i wybór modelu:

$$u = \frac{\frac{k_x}{n_x} - \frac{k_y}{n_y}}{\sqrt{\frac{k_x + k_y}{n_x \cdot n_y} \left(1 - \frac{k_x + k_y}{n_x + n_y}\right)}}$$

3. Sformułowanie hipotezy zerowej: $H_0: p_X = p_Y$
4. Sformułowanie hipotezy alternatywnej: $H_1: p_X < p_Y$
(lewostronny obszar krytyczny)

Ćwiczenie 5- rozwiązanie

5. Określenie wymaganych wartości

$$k_x = 17739; n_x = 129500 + 17739;$$

$$k_y = 17498; n_y = 129741 + 17498;$$

6. Wykonanie obliczeń

$$u = 1,368 \rightarrow p_{value} = 0,9144$$

7. Podjęcie decyzji: brak podstaw do odrzucenia hipotezy zerowej: p -wartość jest duża.

landing_page	new_page	old_page
converted		
0	129741	129500
1	17498	17739

Testy permutacyjne

Testy permutacyjne pozwalają oszacować czy dwie lub więcej prób pochodzi z identycznych rozkładów.

Testy permutacyjne działają w sposób zbliżony do metod bootsprapowych.

Testy sekwencyjne

W podejściu sekwencyjnym elementy próby pobiera się stopniowo.

Etap postępowania w teście sekwencyjnym:

i. Pobór elementu próby

1. Przyjęcie weryfikowanej hipotezy zerowej H_0
2. Odrzucenie weryfikowanej hipotezy zerowej H_0 i przyjęcie hipotezy alternatywnej H_1
3. Brak decyzji: konieczność pobrania kolejnego elementu próby

Testy sekwencyjne

Hipoteza zerowa: $H_0: \theta = \theta_0$

Hipoteza alternatywna: $H_1: \theta = \theta_1 \neq \theta_0$

Statystyka testowa: $Q_n = \prod_{i=1}^k \frac{f(X_i, \theta_1)}{f(X_i, \theta_0)}$ dla $n \in \mathbb{N}$

Postępowanie prowadzi się tak długo jak długo wartość statystyki jest w zakresie od A do B , tzn. $A < q_n < B$

Jeśli:

statystyka testowa w danym kroku przyjmie wartość $q_n < A$ przyjmuje się hipotezę H_0

statystyka testowa w danym kroku przyjmie wartość $q_n > B$ odrzuca się hipotezę H_0
i przyjmuje hipotezę H_1

Testy sekwencyjne

Wartości A i B można przyjąć jako

$$A = \frac{\beta}{1-\alpha} \qquad B = \frac{1-\beta}{\alpha}$$

gdzie α – prawdopodobieństwo błędu pierwszego rodzaju (poziom istotności)

β – prawdopodobieństwo błędu drugiego rodzaju

Sekwencyjny test dla proporcji

Model:

Statystyka testowa $\hat{z}_n = k \cdot \ln \frac{p_1}{p_0} + (n - k) \ln \frac{1-p_1}{1-p_0}$

k – liczba elementów posiadających interesującą cechę (np. użytkowników dokonujących zakupu na stronie)

n – liczba wszystkich elementów próby

W związku z tym, że wyrażenie zostało przekształcone przy użyciu logarytmów stosuje się następujący test

$$\hat{z}_n < \ln A \quad \text{oraz} \quad \hat{z}_n > \ln B$$



03. Testy nieparametryczne

testy niezależności, testy zgodności



Testy nieparametryczne

Zgodności

Niezależności

Inne

Testy zgodności

Służą do wnioskowania o zgodności rozkładu w próbie oraz rozkładu teoretycznego.

Popularne testy zgodności:

- test χ^2 zgodności
- Test Kołmogorowa
- Test normalności Shapiro-Wilka

Test zgodności Kołmogorowa

Hipoteza zerowa: $H_0: F(x) \in \mathcal{D}$

Hipoteza alternatywna: $H_1: F(x) \notin \mathcal{D}$

Obszar krytyczny: prawostronny

Model: Populacja generalna ma dowolny rozkład.

Statystyka testowa $D_n = \sup_x |F_n(x) - F(x)|$ ma rozkład Q


$F_n(x)$ – dystrybuanta empiryczna, $F(x)$ – dystrybuanta empiryczna

W praktyce statystyka próby D_n jest największą różnicą między wartościami dystrybuanty.

Test zgodności Kołmogorowa (przykład)

Wykonano pomiary 124 wartości pewnej cechy badanego zjawiska. Przy użyciu testu Kołmogorowa sprawdzić czy cecha ta ma rozkład normalny.

i	x_i
1	31,2373
2	19,4615
3	27,6216
4	20,1180
5	32,5614
6	24,6040
...	...
123	23,6542
124	24,6073



Test zgodności Kołmogorowa (przykład)

Wykonano pomiary 124 wartości pewnej cechy badanego zjawiska. Przy użyciu testu Kołmogorowa sprawdzić czy cecha ta ma rozkład normalny.

i	x_i	$F_n(x)=i/n$	$F(x)$
1	13,3627	1/124	0,00494141
2	13,5474	2/124	0,00554808
3	16,6867	3/124	0,03174990
4	16,7702	4/124	0,03306975
5	16,8350	5/124	0,03412359
6	17,6420	6/124	0,04972305
...	...	...	...
123	34,0277	123/124	0,97273075
124	36,1427	124/124	0,99142197


$$D_n = \sup_x |F_n(x) - F(x)| = 0,042$$

$$\sqrt{n} \cdot D_n = 0,4707$$

$$p_{value} = 0,624$$

Brak podstaw do odrzucenia hipotezy zerowej.
Można uznać, że próba pochodzi z populacji o rozkładzie normalnym.

Test zgodności Kołmogorowa (przykład – interpretacja graficzna)



Test zgodności χ^2

Hipoteza zerowa: $H_0: F(x) \in \mathcal{D}$

Hipoteza alternatywna: $H_1: F(x) \notin \mathcal{D}$

Obszar krytyczny: prawostronny

Model: Populacja generalna ma dowolny rozkład.

Statystyka testowa $\chi^2 = \sum_{i=1}^k \frac{(n_i - n \cdot p_i)^2}{n \cdot p_i}$ ma rozkład $\chi^2(k - m - 1)$


k – liczba klas empirycznego rozkładu prawdopodobieństwa

m – liczba parametrów rozkładu teoretycznego

Test zgodności χ^2 (przykład)

Wykonano 193 pomiary cechy pewnego zjawiska. Dane w postaci szeregu przedziałowego znajdują się w tabeli. Przy pomocy testu χ^2 sprawdzić czy próba pochodzi z rozkładu normalnego.

i	$[x_i ; x_{i+1})$	n_i
1	0,0 ; 0,2	32
2	0,2 ; 0,4	55
3	0,4 ; 0,6	45
4	0,6 ; 0,8	36
5	0,8 ; 1,0	12
6	1,0 ; 1,2	8
7	1,2 ; 1,4	3
8	1,4 ; 1,6	2



Test zgodności χ^2 (przykład)

Wykonano 193 pomiary cechy pewnego zjawiska. Dane w postaci szeregu przedziałowego znajdują się w tabeli. Przy pomocy testu χ^2 sprawdzić czy próba pochodzi z rozkładu normalnego.

i	$[x_i ; x_{i+1})$	n_i
1	0,0 ; 0,2	32
2	0,2 ; 0,4	55
3	0,4 ; 0,6	45
4	0,6 ; 0,8	36
5	0,8 ; 1,0	12
6	1,0 ; 1,2	8
7	1,2 ; 1,4	3
8	1,4 ; 1,6	2

i	$[x_i ; x_{i+1})$	n_i
1	0,0 ; 0,2	32
2	0,2 ; 0,4	55
3	0,4 ; 0,6	45
4	0,6 ; 0,8	36
5	0,8 ; 1,0	12
6	1,0 ; 1,2	8
7	1,2 ; 1,6	5

Test zgodności χ^2 (przykład)

Wykonano 193 pomiary cechy pewnego zjawiska. Dane w postaci szeregu przedziałowego znajdują się w tabeli. Przy pomocy testu χ^2 sprawdzić czy próba pochodzi z rozkładu normalnego.

i	$[x_i ; x_{i+1})$	n_i	p_i	$n \cdot p_i$
1	0,0 ; 0,2	32	0,1725	33,300
2	0,2 ; 0,4	55	0,2143	41,364
3	0,4 ; 0,6	45	0,2571	49,626
4	0,6 ; 0,8	36	0,2035	39,278
5	0,8 ; 1,0	12	0,1062	20,506
6	1,0 ; 1,2	8	0,0365	7,0584
7	1,2 ; 1,6	5	0,0096	1,8650

$k = 7$ (liczba przedziałów)

$m = 2$ (liczba oszacowanych parametrów)

$$\chi^2 = \sum_{i=1}^k \frac{(n_i - n \cdot p_i)^2}{n \cdot p_i} = 14,174$$

$$p_{value} = 0,00675$$

Hipotezę zerową należy odrzucić.

Ćwiczenie 6

Wiadomo, że pierwsze cyfry transakcji finansowych podlegają rozkładowi Benforda. W przypadku, gdy tak nie jest można podejrzewać, że dochodzi do oszustw finansowych w badanym obszarze. Przy pomocy testu zgodności χ^2 sprawdź czy dostarczone dane podlegają wspomnianemu rozkładowi:

$$P(i) = \log_{10} \left(1 + \frac{1}{i} \right)$$

Dane: `creditcard.csv`.

<https://www.kaggle.com/mlg-ulb/creditcardfraud>


Ćwiczenie 6 - rozwiązanie

1. Przygotowanie danych
 - 1.1. Zamiana liczb na tekst
 - 1.2. Wybór pierwszego znaku od lewej
 - 1.3. Odrzucenie wartości niepoprawnych (które nie są liczbą)
 - 1.4. Zamiana otrzymanych cyfr na liczby typu całkowitego
 - 1.5. Odrzucenie zer

Ćwiczenie 6 - rozwiązanie

1. Przygotowanie danych
2. Sprawdzenie założeń i wybór testu:
test zgodności χ^2
3. Obliczenie prawdopodobieństw rozkładu teoretycznego (Benforda) w odpowiadających kategoriach:

$$P(i) = \log_{10} \left(1 + \frac{1}{i} \right)$$




Ćwiczenie 6 - rozwiązanie

1. Przygotowanie danych
2. Sprawdzenie założeń i wybór testu:
test zgodności χ^2
3. Obliczenie prawdopodobieństw rozkładu teoretycznego (Benforda) w odpowiadających kategoriach:

$$P(i) = \log_{10} \left(1 + \frac{1}{i} \right)$$

4. Obliczenie teoretycznych częstości $P(i)n_i$

i	n_i	$P(i) \cdot n_i$
1	100455	80676
2	42357	47192
3	27930	33483
4	23222	25972
5	18535	21220
6	14081	17941
7	13771	15542
8	12740	13709
9	14912	12263




Ćwiczenie 6 - rozwiązanie

5. Obliczenie statystyki testowej

$$\chi^2 = \sum_{i=1}^k \frac{(n_i - n \cdot P(i))^2}{n \cdot P(i)} = 8569,85$$

$$p_{value} \approx 0$$

6. Podjęcie decyzji: należy odrzucić hipotezę zerową mówiącą, że rozkłady są identyczne




Ćwiczenie 6 - komentarz

Wynik testu może wydawać się zaskakujący, gdyż „na zdrowy rozsądek” rozkłady te są dość podobne. Przyczyny takiego stanu rzeczy są dwie:

1. cyfry uczciwych transakcji podlegają rozkładowi Benforda w przybliżeniu
2. próba jest tak duża, że wynik testu jest bardzo mocny: zatem jeśli się pojawiają duże różnice (np. dla cyfry 1 ~ 20k) to oznacza, że rozkłady w sensie statystycznym nie mogą być identyczne.

Wniosek:

Do wyników testów statystycznych należy podchodzić bardzo ostrożnie.



Ćwiczenie 6 – rozwiązanie (Python)

2. Import danych

```
import scipy.stats as st
df = pd.read_csv("creditcard.csv") # import danych
print(df.columns) # wypisanie nazw kolumn
df.head() # wypisanie kilku początkowych wierszy danych
```

3. Ekstrakcja danych jako tablicy numpy.array

```
x = df["Amount"].values
```

Ćwiczenie 6 – rozwiązanie (Python)

4. Wybranie pierwszych cyfr kwot transakcji

```
# zamień każdą liczbę w x na tekst  
map(str, x)
```

Ćwiczenie 6 – rozwiązanie (Python)

4. Wybranie pierwszych cyfr kwot transakcji (1)

```
# wybierz pierwszy element z każdego tekstu  
# i zamień go na liczbę całkowitą
```

```
map(lambda x: int(x[0]), map(str, x))
```

wybierz pierwszy element
i zamień na liczbę całkowitą

zamień liczbę
na tekst

Ćwiczenie 6 – rozwiązanie (Python)

4. Wybranie pierwszych cyfr kwot transakcji (2)

#przy pomocy funkcji filter wybierz tylko cyfry większe od zera
wybierz pierwszy element z każdego tekstu
i zamień go na liczbę całkowitą

```
filter(lambda x: x>0, map(lambda x: int(x[0]), map(str, x)))
```

wybierz pierwszy element
i zamień na liczbę całkowitą

zamień liczbę
na tekst

Ćwiczenie 6 – rozwiązanie (Python)

4. Wybranie pierwszych cyfr kwot transakcji (3)

```
d = np.fromiter( # utwórz np.array z iteratora...
```

wybierz pierwszy element z każdego tekstu
i zamień go na liczbę całkowitą

```
filter(lambda x: x>0, map(lambda x: int(x[0]), map(str, x)))
```

Jeśli element jest większy
od zera zwróć True

wybierz pierwszy element
i zamień na liczbę całkowitą

zamień liczbę
na tekst

przy pomocy funkcji `filter` wybierz tylko cyfry większe od zera

```
# ... o elementach typu int  
, dtype=int)
```

Ćwiczenie 6 – rozwiązanie (Python)

4. Wybranie pierwszych cyfr kwot transakcji (1-3)

```
d = np.fromiter(  
    filter(lambda x: x>0, map(lambda x: int(x[0]), map(str, x)))  
    , dtype=int)
```

Ćwiczenie 6 – rozwiązanie (Python)

5. Znalezienie unikalnych cyfr i zliczenie ilości każdej z nich

```
(i, ni) = np.unique(d, return_counts=True)
```

6. Obliczenie prawdopodobieństw empirycznych (z próby)

```
pi = ni / sum(ni)
```

Ćwiczenie 6 – rozwiązanie (Python)

7. Obliczenie statystyki testowej

```
nt = rozkladBenforda.pk * sum(ni) # liczebności teoretyczne  
chi2t = sum((ni-nt)**2/nt) # statystyka testowa
```

8. Obliczenie prawdopodobieństw empirycznych (z próby)

```
k = len(i) # liczba klas = liczba cyfr z wyłączeniem zera  
m = 0 # brak parametrów rozkładu oszacowanych na podstawie próby  
df = k-m-1 # liczba stopni swobody  
rozkladChi2 = st.chi2(df) # instancja rozkładu  $\chi^2$   
pvalue = 1 - rozkladChi2.cdf(chi2t) # p-wartość
```

Testy niezależności

Testy niezależności sprawdzają hipotezę, że dwie (lub więcej) zmienne losowe są od siebie niezależne.

Test niezależności χ^2

Hipoteza zerowa: H_0 : Zmienne losowe X i Y są niezależne

Hipoteza alternatywna: H_1 : Zmienne losowe X i Y **nie** są niezależne

Obszar krytyczny: prawostronny

Model: Populacja generalna ma dowolny rozkład.

Statystyka $\chi^2 = \sum_{i=1}^r \sum_{j=1}^s \frac{(n_{ij} - n \cdot p_{i \cdot} \cdot p_{\cdot j})^2}{n \cdot p_{i \cdot} \cdot p_{\cdot j}}$ ma rozkład $\chi^2((r-1) \cdot (s-1))$

Test niezależności χ^2

X Y		Przedziały zmiennej Y				Razem
		1	2	...	s	
Przedziały zmiennej X	1	n_{11}	n_{12}	...	n_{1s}	$n_{1\cdot}$
	2	n_{21}	n_{22}	...	n_{2s}	$n_{2\cdot}$
	...	...	...	...	...	...
	r	n_{r1}	n_{r2}	...	n_{rs}	$n_{r\cdot}$
Razem		$n_{\cdot 1}$	$n_{\cdot 2}$	...	$n_{\cdot s}$	n

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^s \frac{(n_{ij} - n \cdot p_{i\cdot} \cdot p_{\cdot j})^2}{n \cdot p_{i\cdot} \cdot p_{\cdot j}}$$

$$df = (r - 1) \cdot (s - 1)$$

Test niezależności χ^2 (przykład)

Pewien produkt można wytwarzać trzema metodami. Wysłano hipotezę, że wadliwość produkcji nie zależy od metody produkcji. Pobrano próbkę o liczności 400 sztuk i otrzymano następujące wyniki badania jakości dla poszczególnych metod.

Jakość	Metoda produkcji		
	I	II	III
Dobre	100	140	100
Wadliwe	10	30	20

Przyjmując poziom istotności $\alpha=0,05$ zweryfikować hipotezę o niezależności jakości produkcji od metod produkcji.

Test niezależności χ^2 (przykład)

Jakość	Metoda produkcji			Razem
	I	II	III	
Dobre	100	140	100	340
Wadliwe	10	30	20	60
Razem	110	170	120	400

Test niezależności χ^2 (przykład)

p_{ij}	Metoda produkcji			Razem
	I	II	III	
Dobre	0,25	0,35	0,25	0,85
Wadliwe	0,025	0,075	0,05	0,15
Razem	0,275	0,425	0,3	1

Test niezależności χ^2 (przykład)

p_{ij}^T	Metoda produkcji			Razem
	I	II	III	
Dobre	0,275·0,85	0,425·0,85	0,3·0,85	0,85
Wadliwe	0,275·0,15	0,425·0,15	0,3·0,15	0,15
Razem	0,275	0,425	0,3	1

Test niezależności χ^2 (przykład)

p_{ij}^T	Metoda produkcji			Razem
	I	II	III	
Dobre	0,23375	0,36125	0,255	0,85
Wadliwe	0,04125	0,06375	0,045	0,15
Razem	0,275	0,425	0,3	1

Test niezależności χ^2 (przykład)

n_{ij}^T	Metoda produkcji		
	I	II	III
Dobre	93,5	144,5	102
Wadliwe	16,5	25,5	18

Test niezależności χ^2 (przykład)

Jakość	Metoda produkcji		
	I	II	III
Dobre	100	140	100
Wadliwe	10	30	20

n_{ij}^T	Metoda produkcji		
	I	II	III
Dobre	93,5	144,5	102
Wadliwe	16,5	25,5	18

$$df = (2 - 1)(3 - 1) = 2$$

$$\chi^2 = \sum_{i=1}^2 \sum_{j=1}^3 \frac{(n_{ij} - n \cdot p_{i.} \cdot p_{.j})^2}{n \cdot p_{i.} \cdot p_{.j}} = \sum_{i=1}^2 \sum_{j=1}^3 \frac{(n_{ij} - n_{ij}^T)^2}{n_{ij}^T} = 4,20817$$

$$p_{value} = 0,1219 > 0,05$$

Nie ma podstaw do odrzucenia hipotezy zerowej. Liczba wad nie zależy od metody produkcji.

Dzięki za uwagę

infoShareAcademy.com